

ANEXO I

BASE DE DATOS VARIABLES Y TRATAMIENTO DE LA INFORMACIÓN



UNIVERSIDAD
COMPLUTENSE
MADRID

Máster Big Data, Data Science & Inteligencia Artificial
2025-2026

Mónica López Alonso

ANEXO I

BASE DE DATOS VARIABLES Y TRATAMIENTO DE LA INFORMACIÓN

Este anexo documenta la construcción de la base utilizada para modelizar el rating soberano. Incluye las fuentes, el diccionario de variables, las transformaciones, las reglas de depuración, la conversión de las escalas de Moody's, Standard & Poor's y Fitch y la creación del objetivo adelantado un año. La finalidad es permitir que cada observación pueda reconstruirse desde su fuente original hasta la muestra empleada en la estimación.

La base maestra adopta una estructura entidad-año. El universo de referencia contiene 217 países y territorios durante 2000-2024, con 5.425 combinaciones potenciales. Tras exigir la disponibilidad del rating en $t+1$, la muestra modelizable queda formada por 3.434 observaciones de 159 entidades. La especificación fundamental utiliza 71 variables de entrada: 42 variables originales o estructurales, incluidas dos categóricas, y 29 variables temporales derivadas.

Aspecto	Criterio o procedimiento	Resultado
Base inicial	Cuadrícula de 217 países y territorios para el periodo 2000-2024	5.425 observaciones
Integración	Unión de las fuentes mediante la clave iso3-year	Sin duplicados
Control de calidad	Revisión de tipos, unidades, valores constantes e infinitos	Sin inconsistencias estructurales
Cobertura	Exclusión de la especificación principal de las variables con más del 40 % de valores ausentes	71 variables fundamentales
Disponibilidad del objetivo	Selección de observaciones con rating disponible en el periodo siguiente	3.434 observaciones de 159 entidades
Fichero preparado	Incorporación de identificadores, variables derivadas, ratings y variables auxiliares	108 columnas

Tabla 0. Resumen del proceso de integración depuración y selección de la muestra

A.1 FUENTES DE INFORMACIÓN

La información se ha descargado de organismos internacionales, instituciones públicas y fuentes especializadas en calificación crediticia. A la hora de seleccionar las variables de descarga, se priorizó la cobertura internacional, la continuidad temporal, la comparabilidad y la posibilidad de conservar el enlace o fichero de origen, de forma que se pueda repetir el análisis, con más datos, con la mayor facilidad posible. Cada bloque se almacenó por separado, es distintos ficheros antes de la integración.

Fuente	Conjunto	Acceso	Periodo utilizado	Contenido y tratamiento
Banco Mundial	Metadatos de países y WDI	API REST	2000-2024	ISO2, ISO3, país, región, nivel de renta; macroeconomía, sector exterior, variables monetarias y conflicto. Se eliminaron agregados.
Fondo Monetario Internacional	Fiscal Monitor mediante DataMapper	API REST	2000-2024	Deuda pública, saldo fiscal, saldo primario, ingresos y gasto del gobierno general. Los códigos de Kosovo UVK y KOS se normalizaron a XKX.
Banco Mundial	Worldwide Governance Indicators	Excel oficial estático	1996-2024; selección 2000-2024	Se usaron las estimaciones estandarizadas de los seis indicadores WGI.
V-Dem Institute	V-Dem Core	Archivo RData	Selección 2000-2024	Índice de democracia electoral y nombre anual del jefe de gobierno, utilizado para construir duración y rotación gubernamental.
Banco Mundial	Data360 con datos históricos del WEF	API Data360	2007-2017	Global Competitiveness Index. Se conservó en la base maestra, pero se excluyó del modelo principal por cobertura insuficiente.
Fund for Peace	Fragile States Index	Excel anual	2006-2023	Puntuación total de fragilidad. Se normalizaron nombres de países y se convirtieron a ISO3.
Banco de Canadá y Banco de Inglaterra	BoC-BoE Sovereign Default Database 2025	Excel oficial	Histórico 1960-2024; panel 2000-2024	Deuda soberana en default y variables de historial. Los años anteriores a 2000 se conservaron para calcular antecedentes de 5 y 10 años.
CountryEconomy	Históricos soberanos de Moody's, S&P y Fitch	Tablas HTML	Histórico disponible hasta 2025	Fuente principal de eventos de rating. Se mantuvieron fechas anteriores a 2000 para determinar el rating vigente al inicio del panel.
Trading Economics	Páginas públicas de rating	Tablas HTML	Histórico disponible hasta 2025	Fuente complementaria para entidades no cubiertas por CountryEconomy. Se incorporaron históricos utilizables de 16 entidades.

Tabla A1 Fuentes utilizadas para construir la base

A.1.1 DIRECCIONES DE DESCARGA Y CONSULTA

Fuente	Dirección
Banco Mundial WDI	https://api.worldbank.org/v2
FMI DataMapper	https://www.imf.org/external/datamapper/api/v2
WGI	https://datacatalog.worldbank.org/search/dataset/0038026/worldwide-governance-indicators
V-Dem	https://github.com/vdeminstitute/vdemdata
Data360	https://data360.worldbank.org
Fragile States Index	https://fragilestatesindex.org/excel/
BoC-BoE Sovereign Default Database	https://www.bankofcanada.ca/2025/10/staff-analytical-note-2025-24/
CountryEconomy ratings	https://countryeconomy.com/ratings
Trading Economics ratings	https://tradingeconomics.com/country-list/rating

Tabla A2 Direcciones utilizadas en los notebooks

Algunas variables requieren una aclaración adicional sobre su procedencia y proceso de descarga. El indicador de *conflicto* se obtuvo a través de [World Development Indicators \(WDI\)](#), aunque la fuente original de la información es el [Uppsala Conflict Data Program \(UCDP\)](#). De forma similar, las variables de *tipo de interés real y préstamos no productivos* se descargaron mediante [WDI](#), si bien proceden originalmente de estadísticas del [Fondo Monetario Internacional \(FMI\)](#).

En el caso de los [Worldwide Governance Indicators \(WGI\)](#), se utilizó el fichero oficial estático descargable en lugar de la API, debido a que esta no proporcionaba una extracción suficientemente estable para el conjunto de países y años considerados.

A.1.2 PANELES INTERMEDIOS

Bloque	Fichero procesado	Filas	Columnas	Entidades	Periodo
Macroeconómico	wdi_macro_panel_2000_2024.csv	5.425	16	217	2000-2024
Fiscal	imf_fiscal_panel_2000_2024.csv	5.425	12	217	2000-2024
Exterior	wdi_external_panel_2000_2024.csv	5.425	18	217	2000-2024
Monetario y financiero	wdi_monetary_financial_panel_2000_2024.csv	5.425	8	217	2000-2024
Institucional	wgi_institutional_panel_2000_2024.csv	5.425	12	217	2000-2024
Democracia	vdem_democracy_panel_2000_2024.csv	5.425	7	217	2000-2024
Política complementaria	political_complementary_panel_2000_2024.csv	5.425	13	217	2000-2024
Conflicto	wdi_conflict_panel_2000_2024.csv	5.425	9	217	2000-2024
Default soberano	boc_boe_sovereign_default_panel_2000_2024.csv	5.425	12	217	2000-2024
Ratings	government_credit_rating_mean_2000_2025.csv	4.160	18	160	2000-2025

Tabla A3 Paneles integrados y dimensiones comprobadas

A.2 ESTRUCTURA DE LA BASE

La base de datos principal se preparó a partir del listado de países y economías obtenidos del Banco Mundial; la cual tenía 217 entidades. Los agregados regionales y económicos se eliminaron y se generaron todas las combinaciones entre las 217 entidades válidas y los 25 años del periodo 2000-2024. Cada bloque se unió mediante la clave compuesta iso3-year con validación uno a uno. Obteniendo así 5.425 observaciones.

Posteriormente se descargó la variable objetivo y si alineó con las variables predictoras de tal forma que los predictores del año t se asocian con el rating medio del año $t+1$.




Figura A1 Flujo de construcción de la base. Fuente: elaboración propia a partir de los notebooks

Con fines descriptivos, se crea la variable `economic_period`, la cual permite agrupar los años de la muestra según distintos contextos macroeconómicos sin modificar ni sustituir la variable temporal original.

Se definieron seis intervalos:

- Precrisis 2000-2007.
- Crisis financiera 2008-2009.
- Crisis de deuda 2010-2012.
- Recuperación 2013-2019.
- Pandemia 2020-2021 e inflación.
- Endurecimiento monetario 2022-2024.

Esta clasificación se utiliza principalmente para facilitar el análisis descriptivo y la comparación de la evolución de las variables y de las calificaciones soberanas entre distintos entornos económicos. Los intervalos no pretenden establecer una periodización económica universal, sino proporcionar una referencia común y coherente para interpretar temporalmente los resultados del estudio.

A.3 DICCIONARIO DE VARIABLES

Este diccionario describe todas las variables utilizadas en el proyecto, distinguiendo entre las variables utilizadas por el modelo fundamental, las variables auxiliares y las variables de rating.

Las tablas A4 a A13 recogen el nombre empleado en Python, el código de la fuente, la unidad y un breve resumen del indicador/varibale.

Bloque	Originales	Derivadas	Total	Contenido
Categorías	2	0	2	Región y nivel de renta
Macroeconómico	8	8	16	Actividad, desarrollo, inflación, empleo, inversión y ahorro
Fiscal	6	11	17	Deuda, saldos, ingresos, gasto e intereses
Sector exterior	7	6	13	Cuenta corriente, comercio, IED y reservas
Monetario y financiero	1	4	5	Tipo de interés real
Institucional	6	0	6	Seis indicadores WGI
Democracia	1	0	1	Índice de democracia electoral
Político	5	0	5	Duración y cambios de gobierno, fragilidad
Default soberano	6	0	6	Impago actual e historial
Total	42	29	71	Incluye region e income_level

Tabla A4 Resumen de las 71 variables de entrada

A.3.1 IDENTIFICADORES Y VARIABLES AUXILIARES

Variable	Descripción	Tipo	Uso
iso3	Código ISO 3166-1 alpha-3 armonizado; clave principal de entidad.	Texto	Identificador; no predictor
iso2	Código ISO 3166-1 alpha-2 de la entidad.	Texto	Identificador; no predictor
country	Nombre armonizado del país o territorio.	Texto	Identificador; no predictor
year	Año de observación de las variables explicativas.	Entero	Clave temporal; no predictor
economic_period	Etapa económica asignada al año: precrisis, crisis financiera, crisis de deuda, recuperación, pandemia o inflación y endurecimiento.	Categoría	Descriptiva; no predictor
data_split	Partición temporal: train, validation o test.	Categoría	Control del diseño; no predictor
target_year	Año del rating objetivo, calculado como year + 1.	Entero	Auxiliar; no predictor

Tabla A5 Identificadores y variables auxiliares

A.3.2 VARIABLES MACROECONÓMICAS Y CATEGÓRICAS

Variable	Código o fuente	Unidad	Definición
region	Metadatos Banco Mundial	Categoría	Región geográfica de la entidad; se codifica mediante variables indicadoras dentro del pipeline.
income_level	Metadatos Banco Mundial	Categoría	Grupo de renta del Banco Mundial; aproxima el nivel de desarrollo económico.
gdp_growth_pct	NY.GDP.MKTP.KD.ZG	% anual	Crecimiento anual del PIB real a precios constantes.
gdp_per_capita_constant_2015_usd	NY.GDP.PCAP.KD	USD constantes de 2015	PIB real por habitante; aproxima renta y capacidad productiva media.
gdp_ppp_constant_2021_intl_usd	NY.GDP.MKTP.PP.KD	USD internacionales constantes de 2021	Tamaño real de la economía ajustado por paridad del poder adquisitivo.
gdp_per_capita_ppp_constant_2021_intl_usd	NY.GDP.PCAP.PP.KD	USD internacionales constantes de 2021 por habitante	Nivel económico por habitante ajustado por diferencias de precios.
inflation_cpi_pct	FP.CPI.TOTL.ZG	% anual	Variación anual del índice de precios de consumo; refleja estabilidad de precios.
unemployment_pct	SL.UEM.TOTL.ZS	% de la población activa	Tasa de desempleo modelizada por la OIT y difundida por WDI.
investment_pct_gdp	NE.GDI.TOTL.ZS	% del PIB	Formación bruta de capital; mide el esfuerzo inversor de la economía.
gross_savings_pct_gdp	NY.GNS.ICTR.ZS	% del PIB	Ahorro bruto disponible para financiar inversión y reducir dependencia exterior.

Tabla A6 Diccionario del bloque macroeconómico y categórico

A.3.3 VARIABLES FISCALES

Variable	Código o fuente	Unidad	Definición
government_debt_pct_gdp	G_XWDG_G01_GDP_PT	% del PIB	Deuda bruta del gobierno general en relación con el tamaño de la economía.
fiscal_balance_pct_gdp	GGXCNL_G01_GDP_PT	% del PIB	Saldo global del gobierno general; positivo indica superávit y negativo, déficit.
primary_balance_pct_gdp	GGXONLB_G01_GDP_PT	% del PIB	Saldo del gobierno general antes de pagos netos de intereses.
government_revenue_pct_gdp	GGR_G01_GDP_PT	% del PIB	Ingresos del gobierno general y capacidad recaudatoria.
government_expenditure_pct_gdp	G_X_G01_GDP_PT	% del PIB	Gasto total del gobierno general.
net_interest_payments_pct_gdp	Cálculo FMI	% del PIB	Carga neta de intereses, calculada como saldo primario menos saldo fiscal.

Tabla A7 Diccionario del bloque fiscal

A3.4 VARIABLES DEL SECTOR EXTERIOR

Variable	Código o fuente	Unidad	Definición
current_account_balance_pct_gdp	BN.CAB.XOKA.GD.ZS	% del PIB	Saldo de bienes, servicios, rentas y transferencias frente al exterior.
exports_growth_pct	NE.EXP.GNFS.KD.ZG	% anual real	Crecimiento real de las exportaciones de bienes y servicios.
exports_pct_gdp	NE.EXP.GNFS.ZS	% del PIB	Peso de las exportaciones de bienes y servicios en la economía.
imports_pct_gdp	NE.IMP.GNFS.ZS	% del PIB	Peso de las importaciones de bienes y servicios en la economía.
trade_openness_pct_gdp	Cálculo WDI	% del PIB	Apertura comercial: suma de exportaciones e importaciones sobre el PIB.
fdi_net_inflows_pct_gdp	BX.KLT.DINV.WD.GD.ZS	% del PIB	Entradas netas de inversión extranjera directa; puede ser negativa por desinversiones.
reserves_months_imports	FI.RES.TOTL.MO	Meses	Número aproximado de meses de importaciones cubiertos por las reservas internacionales.

Tabla A8 Diccionario del sector exterior

A.3.5 VARIABLES MONETARIAS Y FINANCIERAS

Variable	Código o fuente	Unidad	Definición
real_interest_rate_pct	FR.INR.RINR	% anual	Tipo de interés aplicado a préstamos ajustado por inflación; aproxima el coste real de financiación.

Tabla A9 Diccionario del bloque monetario y financiero

A.3.6 VARIABLES INSTITUCIONALES

Variable	Código o fuente	Unidad	Definición
political_stability_estimate	PV.EST	Estimación estandarizada	Percepción de estabilidad política y ausencia de violencia o terrorismo.
government_effectiveness_estimate	GE.EST	Estimación estandarizada	Calidad de servicios públicos, Administración y ejecución de políticas.
rule_of_law_estimate	RL.EST	Estimación estandarizada	Confianza en las normas, contratos, derechos de propiedad, policía y tribunales.
control_of_corruption_estimate	CC.EST	Estimación estandarizada	Grado en que el poder público no se utiliza para obtener beneficios privados.
regulatory_quality_estimate	RQ.EST	Estimación estandarizada	Capacidad para formular y aplicar regulación favorable al sector privado.
voice_accountability_estimate	VA.EST	Estimación estandarizada	Participación ciudadana, libertad de expresión y rendición de cuentas.

Tabla A10 Diccionario del bloque institucional

A.3.7 DEMOCRACIA

Variable	Código o fuente	Unidad	Definición
electoral_democracy_index	V-Dem v2x_polyarchy	Escala 0-1	Grado de democracia electoral; valores altos indican elecciones más libres, amplias y competitivas.

Tabla A11 Diccionario de democracia

A.3.8 VARIABLES POLÍTICAS

Variable	Código o fuente	Unidad	Definición
head_of_government_tenure_years	V-Dem v2exnamhog	Años	Número de años consecutivos del jefe de gobierno observado en el cargo.
average_government_duration_since_2000	Cálculo V-Dem	Años	Duración media de los gobiernos observados desde 2000 hasta el año analizado.
government_change_dummy	Cálculo V-Dem	0/1	Toma 1 cuando cambia el jefe de gobierno respecto al año anterior consecutivo.
government_changes_previous_5y	Cálculo V-Dem	Número	Cambios de jefe de gobierno entre t-5 y t-1; excluye el año actual.
fragile_states_index	Fund for Peace	Escala aproximada 0-120	Vulnerabilidad estructural del Estado; valores altos indican mayor fragilidad.

Tabla A12 Diccionario del bloque político

A.3.9 HISTORIAL DE DEFAULT SOBERANO

Variable	Código o fuente	Unidad	Definición
sovereign_debt_in_default_usd_mn	BoC-BoE DEBT_TOTAL_2025	Millones de USD	Valor nominal de obligaciones públicas en default o reestructuración.
sovereign_default_dummy	Cálculo BoC-BoE	0/1	Toma 1 si existe deuda soberana en default en el año.
default_previous_5y	Cálculo BoC-BoE	0/1	Toma 1 si hubo default en alguno de los cinco años anteriores, excluido t.
default_previous_10y	Cálculo BoC-BoE	0/1	Toma 1 si hubo default en alguno de los diez años anteriores, excluido t.
years_since_last_default	Cálculo BoC-BoE	Años	Años transcurridos desde el último default; para países sin episodio se usa la longitud de historia observada.
never_default_history_dummy	Cálculo BoC-BoE	0/1	Toma 1 si no existe ningún default registrado desde 1960 hasta el año analizado.

Tabla A13 Diccionario del historial de default

A.3.10 VARIABLES DE RATING Y DISPONIBILIDAD

Variable	Descripción	Rango	Función
moodys_score	Puntuación Moody's vigente al cierre del año.	0-100 o ausente	Descriptiva del panel de ratings
sp_score	Puntuación S&P vigente al cierre del año.	0-100 o ausente	Descriptiva del panel de ratings
fitch_score	Puntuación Fitch vigente al cierre del año.	0-100 o ausente	Descriptiva del panel de ratings
number_of_ratings	Número de agencias con calificación activa.	0-3	Denominador de la media
has_at_least_one_rating	Indica si existe al menos una calificación activa.	0/1	Control de disponibilidad
rating_score_min	Puntuación más baja entre las agencias activas.	0-100	Desacuerdo entre agencias
rating_score_max	Puntuación más alta entre las agencias activas.	0-100	Desacuerdo entre agencias
rating_score_range	Diferencia entre rating_score_max y rating_score_min.	Puntos	Desacuerdo entre agencias
rating_score_std	Desviación típica de las puntuaciones; se fija en 0 cuando solo existe una agencia.	Puntos	Desacuerdo entre agencias
rating_score_mean_t	Media de agencias observada en el mismo año que los predictores.	0-100	Predictor solo en el modelo ampliado y benchmark
rating_score_mean_t1	Media de agencias del año siguiente.	0-100	Variable objetivo principal
rating_change_t1	Diferencia rating_score_mean_t1 - rating_score_mean_t.	Puntos	Objetivo complementario de cambio

Tabla A14 Variables del panel de ratings y del objetivo

La disponibilidad de calificaciones no es homogénea entre países, años y agencias, por lo que las puntuaciones individuales se conservaron junto con variables específicas de cobertura. La variable `rating_score_mean_t` se calcula únicamente con las agencias disponibles en cada observación, utilizando `number_of_ratings` como denominador efectivo y sin interpretar la ausencia de una calificación como una puntuación nula. A partir de esta media se construye `rating_score_mean_t1`, correspondiente al nivel medio observado en el año siguiente y utilizado como variable objetivo principal. De forma complementaria, `rating_change_t1` recoge la variación interanual de la calificación media y permite estudiar específicamente los episodios de mejora, deterioro o estabilidad.

La información contemporánea de rating se excluye del modelo fundamental principal y se incorpora únicamente en especificaciones ampliadas y ejercicios de benchmark, evitando que la predicción dependa directamente de la propia calificación que se pretende estimar.

A.4 VARIABLES DERIVADAS

Las variables derivadas se calcularon después de ordenar las observaciones por iso3 y year. Las operaciones móviles usan únicamente el año t y años anteriores; las diferencias y ventanas nunca acceden a t+1. De esta forma, las transformaciones no introducen información futura.

A.4.1 DERIVACIONES ESTRUCTURALES

Variable	Regla de cálculo	Interpretación
economic_period	Clasificación de year	2000-2007 precrisis; 2008-2009 crisis financiera; 2010-2012 crisis de deuda; 2013-2019 recuperación; 2020-2021 pandemia; 2022-2024 inflación y endurecimiento.
net_interest_payments_pct_gdp	primary_balance_pct_gdp - fiscal_balance_pct_gdp	Carga neta de intereses sobre el PIB.
trade_openness_pct_gdp	exports_pct_gdp + imports_pct_gdp	Grado de apertura comercial.
head_of_government_tenure_years	Recuento dentro de cada mandato consecutivo	Antigüedad del jefe de gobierno.
average_government_duration_since_2000	Años observados / número de mandatos	Duración media acumulada de los gobiernos.
government_change_dummy	1 si el nombre cambia entre años consecutivos	Cambio de jefe de gobierno en t.
government_changes_previous_5y	Suma móvil de government_change_dummy desplazada un año	Número de cambios entre t-5 y t-1.
sovereign_default_dummy	1 si sovereign_debt_in_default_usd_mn > 0	Impago soberano actual.
default_previous_5y	Máximo móvil de sovereign_default_dummy desplazado un año	Default en los cinco años anteriores.
default_previous_10y	Máximo móvil de sovereign_default_dummy desplazado un año	Default en los diez años anteriores.
years_since_last_default	year - last_default_year	Distancia temporal al último impago.
never_default_history_dummy	1 si last_default_year está ausente	Ausencia de defaults registrados.
armed_conflict_dummy	1 si battle_related_deaths > 0	Indicador de conflicto; excluido del modelo principal por cobertura.
log_battle_related_deaths	log(1 + battle_related_deaths)	Transformación de intensidad de conflicto; excluida por cobertura.

Tabla A15 Variables derivadas durante la construcción de los bloques

A.4.2 VARIABLES TEMPORALES DE LA ESPECIFICACIÓN FINAL

La especificación definitiva incorporó 29 variables temporales comunes. Las ventanas de tres años exigen tres observaciones y la media real de cinco años exige cinco; si la ventana no está completa, el resultado permanece ausente y se trata posteriormente dentro del pipeline.

Variable	Cálculo	Contenido
gdp_growth_3y_mean	Media móvil de gdp_growth_pct en t, t-1 y t-2	Crecimiento medio reciente; exige 3 datos.
gdp_growth_3y_std	Desviación móvil de gdp_growth_pct en t, t-1 y t-2	Volatilidad reciente del crecimiento; exige 3 datos.
recession_dummy	1 si gdp_growth_pct < 0	Identifica recesión en el año t; se mantiene ausente si falta el crecimiento.
inflation_abs	Valor absoluto de inflation_cpi_pct	Captura desviaciones inflacionarias y deflacionarias.
high_inflation_dummy	1 si inflation_cpi_pct > 10	Identifica episodios de inflación elevada.
inflation_3y_std	Desviación móvil de inflation_cpi_pct en 3 años	Volatilidad reciente de la inflación.
unemployment_change	unemployment_pct_t - unemployment_pct_t-1	Cambio anual del desempleo.
saving_investment_gap	gross_savings_pct_gdp - investment_pct_gdp	Necesidad o capacidad aproximada de financiación.
government_debt_change	government_debt_pct_gdp_t - valor_t-1	Cambio anual de la ratio de deuda pública.
government_debt_3y_change	government_debt_pct_gdp_t - valor_t-3	Cambio acumulado de deuda en tres años.
fiscal_balance_3y_mean	Media móvil de fiscal_balance_pct_gdp en 3 años	Posición fiscal media reciente.
fiscal_deficit_dummy	1 si fiscal_balance_pct_gdp < 0	Identifica déficit fiscal en t.
persistent_deficit_dummy	1 si fiscal_balance_pct_gdp < 0 en los 3 años	Identifica déficit fiscal persistente; exige 3 datos.
primary_balance_3y_mean	Media móvil de primary_balance_pct_gdp en 3 años	Saldo primario medio reciente.
primary_deficit_dummy	1 si primary_balance_pct_gdp < 0	Identifica déficit primario en t.
government_revenue_change	government_revenue_pct_gdp_t - valor_t-1	Cambio anual de los ingresos públicos.
government_revenue_3y_mean	Media móvil de government_revenue_pct_gdp en 3 años	Capacidad recaudatoria media reciente.
government_expenditure_change	government_expenditure_pct_gdp_t - valor_t-1	Cambio anual del gasto público.
government_expenditure_3y_mean	Media móvil de government_expenditure_pct_gdp en 3 años	Nivel medio reciente de gasto.
current_account_3y_mean	Media móvil de current_account_balance_pct_gdp en 3 años	Posición exterior media reciente.
current_account_deficit_dummy	1 si current_account_balance_pct_gdp < 0	Identifica déficit exterior en t.
persistent_current_account_deficit	1 si la cuenta corriente es negativa en los 3 años	Identifica déficit exterior persistente; exige 3 datos.
exports_growth_3y_mean	Media móvil de exports_growth_pct en 3 años	Crecimiento exportador medio reciente.
exports_growth_3y_std	Desviación móvil de exports_growth_pct en 3 años	Volatilidad reciente de las exportaciones.
exports_contraction_dummy	1 si exports_growth_pct < 0	Identifica contracción de las exportaciones.
real_interest_rate_5y_mean	Media móvil de real_interest_rate_pct en 5 años	Coste real medio de financiación; exige 5 datos.
real_interest_rate_3y_std	Desviación móvil de real_interest_rate_pct en 3 años	Volatilidad reciente del tipo real.
real_interest_rate_change	real_interest_rate_pct_t - valor_t-1	Cambio anual del tipo de interés real.
negative_real_interest_dummy	1 si real_interest_rate_pct < 0	Identifica tipos de interés reales negativos.

Tabla A16 Diccionario de las 29 variables derivadas finales

A5 INTEGRACIÓN LIMPIEZA Y CONTROL DE CALIDAD

A.5.1 HOMOGENEIZACIÓN

Los nombres y códigos geográficos se armonizaron antes de las uniones. Se utilizó ISO3 como identificador principal, country_converter para equivalencias automáticas y diccionarios manuales para denominaciones especiales. En los datos fiscales, UVK y KOS se sustituyeron por XKX. En ratings, FSI y otras fuentes se corrigieron nombres históricos, traducciones, territorios y variantes ortográficas sin asignar códigos de forma arbitraria.

Las fechas se convirtieron a formato temporal y year a entero anulable. Los indicadores se transformaron a valores numéricos mediante coerción controlada. Los textos se limpiaron de espacios y encabezados repetidos. Los paneles en formato largo se pasaron a formato ancho y se ordenaron por iso3-year. Después de cada unión se exigió una relación uno a uno.

En la base de default, la ausencia de un importe registrado se interpretó como cero, porque la fuente enumera los episodios de impago. Esta regla no se extendió al resto de bloques. En conflicto, por ejemplo, un valor ausente no se sustituyó por cero, ya que la falta de dato no demuestra la inexistencia de conflicto.

A.5.2 VALORES AUSENTES

La auditoría se realizó sobre 52 variables explicativas disponibles antes de la selección final. Se midió la ausencia tanto en el panel completo como en las 3.434 observaciones con objetivo. La decisión de exclusión se basó en esta última muestra, porque es la que realmente interviene en los modelos.




Figura A2 Distribución de las variables según su porcentaje de ausentes en la muestra modelizable

Grupo de ausencia	Número de variables
0 %	6
0-10 %	28
10-20 %	3
20-40 %	5
Más del 40 %	10
100 %	0

Tabla A17 Clasificación inicial de la cobertura

No se eliminaron filas por contener algún predictor ausente. Las variables con más del 40 % de valores ausentes en la muestra con objetivo se excluyeron de la especificación principal, pero se conservaron en la base maestra para análisis ampliados. Las variables por debajo del umbral se mantuvieron y se imputaron dentro del pipeline utilizando únicamente el conjunto de entrenamiento.

A.5.3 VARIABLES EXCLUIDAS O NO INCORPORADAS

Variable	Ausencia en muestra	Motivo	Tratamiento
external_debt_pct_gni	≈ 47 %	Cobertura insuficiente en la muestra con objetivo	Conservada en la base maestra; fuera del modelo principal
external_debt_service_pct_exports	≈ 48 %	Cobertura insuficiente	Conservada en la base maestra
external_debt_stocks_current_usd	≈ 47 %	Cobertura insuficiente	Conservada en la base maestra
reserves_pct_external_debt	≈ 52 %	Cobertura insuficiente	Conservada en la base maestra
short_term_debt_pct_reserves	≈ 52 %	Cobertura insuficiente	Conservada en la base maestra
bank_npl_pct_gross_loans	≈ 44 %	Cobertura insuficiente	Conservada en la base maestra
global_competitiveness_index	≈ 62 %	Serie disponible principalmente entre 2007 y 2017	Conservada en la base maestra
battle_related_deaths	≈ 85 %	Cobertura insuficiente	Conservada en la base maestra
armed_conflict_dummy	≈ 85 %	Depende de la variable de conflicto con baja cobertura	Conservada en la base maestra
log_battle_related_deaths	≈ 85 %	Depende de la variable de conflicto con baja cobertura	Conservada en la base maestra
head_of_government	≈ 39 %	826 categorías y escasa capacidad de generalización	Excluida como predictor; se conservan duración y cambios
exchange_rate_lcu_per_usd	Baja ausencia	El nivel nominal no es comparable entre monedas y fue retirado de la lista final	No forma parte de las 71 variables

Tabla A18 Variables excluidas de la especificación fundamental final

La tabla distingue la exclusión del modelo de la eliminación física. Salvo el uso predictivo, las columnas permanecen disponibles en los paneles procesados. El nombre del jefe de gobierno se retiró por su elevada cardinalidad y se sustituyó conceptualmente por variables generalizables de duración y rotación. El nivel del tipo de cambio también se retiró de la lista final porque las unidades monetarias no son comparables entre países.

A.5.4 INDICADORES FINANCIEROS EXPLORADOS

Ante la baja cobertura del bloque financiero se descargaron cinco indicadores alternativos para comparar su disponibilidad. Esta exploración no modificó el fichero monetario-financiero finalmente integrado, por lo que las variables siguientes no forman parte de las 71 entradas.

Variable	Código WDI	Ausencia	Resultado
lending_interest_rate_pct	FR.INR.LEND	43,35 % en el panel completo	Explorada; no integrada en el panel final
interest_rate_spread_pct	FR.INR.LNDP	47,52 %	Explorada; no integrada
bank_capital_to_assets_pct	FB.BNK.CAPA.ZS	59,23 %	Explorada; no integrada
domestic_credit_private_sector_banks_pct_gdp	FD.AST.PRVT.GD.ZS	20,63 %	Explorada; no integrada
domestic_credit_private_sector_pct_gdp	FS.AST.PRVT.GD.ZS	26,10 %	Explorada; no integrada

Tabla A19 Indicadores financieros exploratorios no incorporados

A.5.5 RANGOS DUPLICADOS E INCONSISTENCIAS

Control	Procedimiento	Resultado
Clave	Unicidad de iso3-year en todos los paneles	0 duplicados en los paneles integrados y en la base final
Estructura	217 entidades x 25 años	5.425 observaciones esperadas y obtenidas
Tipos	Conversión de year y variables numéricas con control de errores	Sin claves inválidas en la integración final
Constantes	Número de valores únicos por predictor	0 variables constantes
Infinitos	Comprobación de valores numéricos	0 variables con valores infinitos
Binarias	Valores permitidos 0 y 1	0 valores inválidos
Rangos	Desempleo, NPL y ratings entre 0 y 100	0 valores fuera de rango
No negatividad	Variables de stock, duración, reservas y recuentos	0 valores negativos tras el tratamiento
Default	Revisión del importe de deuda en impago	1 valor negativo detectado y recortado a 0
Rating	Calificaciones activas incluidas en la escala	7.901 transformadas y 0 activas sin correspondencia
Media de agencias	Cálculo agrupado frente a cálculo por columnas	Diferencia máxima 0 y 0 discrepancias en el número de ratings
Alineación temporal	rating_year = year + 1	0 alineaciones incorrectas

Tabla A20 Controles de calidad aplicados

Los valores extremos económicamente plausibles no se eliminaron de forma automática. Una hiperinflación, una deuda superior al 100 % del PIB, una recesión profunda o una crisis fiscal pueden contener información relevante sobre el riesgo soberano. La auditoría solo corrigió valores incompatibles con la definición de una variable.

A.5.6 PREPROCESAMIENTO POSTERIOR A LA DIVISIÓN TEMPORAL

La base se guardó sin imputar y sin escalar. Los parámetros del preprocesamiento se estimaron después de la división temporal y exclusivamente con entrenamiento. Este orden evita que la mediana, las categorías o los parámetros de escala incorporen información de validación o test.

- **Rama A**, formada por modelos sensibles a la escala: las variables continuas se imputaron mediante la mediana, las binarias mediante la moda y las categóricas mediante su categoría más frecuente. Se añadieron indicadores de ausencia y las variables `region` e `income_level` se codificaron mediante one-hot encoding. Para reducir la asimetría, se aplicó la transformación $\log(1 + x)$ al PIB per cápita, al PIB PPA, al PIB per cápita PPA y a la deuda soberana en default. Posteriormente, las variables se escalaron mediante RobustScaler y se revisaron posibles redundancias utilizando correlaciones y factores de inflación de la varianza (VIF).

Transformaciones específicas de la Rama A

Variables transformadas para reducir la asimetría antes del escalado robusto

Variable original	Transformación aplicada
<code>gdp_per_capita_constant_2015_usd</code>	$\log(1 + \text{PIB per cápita})$
<code>gdp_ppp_constant_2021_intl_usd</code>	$\log(1 + \text{PIB PPA})$
<code>gdp_per_capita_ppp_constant_2021_intl_usd</code>	$\log(1 + \text{PIB per cápita PPA})$
<code>sovereign_debt_in_default_usd_mn</code>	$\log(1 + \text{deuda soberana en default})$

Nota: $\log(1 + x)$ permite conservar los valores iguales a cero y comprimir las distribuciones muy asimétricas.

- **Rama B** de árboles y ensembles: imputación de continuas con la mediana y de binarias con la moda, indicadores de ausencia y categoría Missing para variables categóricas antes de one-hot. No se aplicaron escalado ni transformaciones logarítmicas por asimetría, y los valores extremos plausibles se conservaron.
- En todos los casos, validación y test se transformaron con los parámetros aprendidos en entrenamiento, sin reestimación.

A.6 CONSTRUCCIÓN DEL PANEL DE RATINGS

Los históricos de CountryEconomy y Trading Economics se recopilaron como eventos. Cada evento conserva la entidad, la agencia, la fecha, la cadena original, el alcance del rating, la fuente y la URL. CountryEconomy recibió prioridad 1 y Trading Economics prioridad 2 cuando ambas fuentes contenían exactamente el mismo evento.

CountryEconomy aportó 7.440 filas brutas de 144 páginas. Tras convertir las fechas, el histórico principal contenía 6.695 eventos entre 2000 y 2024, 111 eventos de 2025 y 462 eventos anteriores a 2000. Estos últimos no se eliminaron porque determinan el rating vigente al inicio del panel. Trading Economics añadió históricos utilizables para 16 entidades. Ocho eventos de 2026 y un duplicado de Eswatini quedaron fuera del periodo final.

A.6.1 SEPARACIÓN DEL GRADO LA PERSPECTIVA Y EL ESTADO

Estado	Significado	Tratamiento anual
active	Contiene un grado válido	Se convierte a la escala 0-100 y se mantiene vigente hasta otro evento.
outlook_only	Solo cambia la perspectiva	Se actualiza la perspectiva sin sustituir el último grado conocido.
withdrawn	Retirada o no calificado	El grado y la perspectiva pasan a ausente; el rating deja de arrastrarse.
not_yet_rated	Año anterior al primer rating	Permanece ausente; no se rellena hacia atrás.
unparsed	Cadena no interpretada	Se separa para revisión y no se transforma automáticamente.

Tabla A21 Estados utilizados al interpretar los eventos de rating

El panel anual contiene una fila por entidad, agencia y año y utiliza como fecha de referencia el 31 de diciembre. El último grado válido continúa vigente mientras la agencia no publique un cambio o una retirada. Este arrastre representa la vigencia oficial de la calificación y no una imputación estadística. Los años anteriores al primer rating permanecen ausentes.




Figura A3 Transformación de los eventos de rating en la variable objetivo

A.6.2 CONVERSIÓN DE LAS ESCALAS

Las categorías alfabéticas se transformaron en una escala común de 0 a 100. El valor 100 representa la máxima calidad crediticia y la puntuación disminuye en intervalos de cinco puntos. Solo se convirtieron eventos activos. Un rating retirado o inexistente permaneció ausente y nunca se confundió con default.

Puntuación	Moody's	S&P	Fitch
100	Aaa	AAA	AAA
95	Aa1	AA+	AA+
90	Aa2	AA	AA
85	Aa3	AA-	AA-
80	A1	A+	A+
75	A2	A	A
70	A3	A-	A-
65	Baa1	BBB+	BBB+
60	Baa2	BBB	BBB
55	Baa3	BBB-	BBB-
50	Ba1	BB+	BB+
45	Ba2	BB	BB
40	Ba3	BB-	BB-
35	B1	B+	B+
30	B2	B	B
25	B3	B-	B-
20	Caa1	CCC+	CCC+
15	Caa2	CCC	CCC
10	Caa3	CCC-	CCC-
5	Ca	CC / C	CC / C
0	C	SD / D	RD / D

Tabla A22 Correspondencia entre las escalas de rating

En las categorías inferiores, C de Moody's equivale a 0, mientras que C de S&P y Fitch equivale a 5. Las categorías SD de S&P y RD de Fitch representan default selectivo o restringido y reciben 0, al igual que D. El control final encontró 7.901 observaciones activas, todas transformadas correctamente.

A.6.3 RATING MEDIO POR ENTIDAD Y AÑO

Para cada entidad y año se calculó la media aritmética de las puntuaciones disponibles de Moody's, S&P y Fitch. Dado que las calificaciones de las tres agencias se transformaron previamente a una escala común de 0 a 100, sus puntuaciones pueden agregarse de forma homogénea.

Si únicamente existe una agencia calificadora para una determinada entidad y año, la media coincide con su puntuación. Cuando existen dos o tres calificaciones, el denominador corresponde al número real de ratings disponibles:

$$Rating\ medio_{i,t} = \frac{\sum_{a=1}^{N_{i,t}} Score_{i,t,a}}{N_{i,t}}$$

donde $N_{i,t}$ representa el número de agencias con una calificación vigente para la entidad i en el año t . La ausencia de rating por parte de una agencia no se considera una puntuación nula ni se imputa, sino que dicha agencia se excluye del cálculo de la media.

El panel anual por agencia contiene 9.932 filas correspondientes a 160 entidades y las tres agencias consideradas durante el periodo 2000-2025. De ellas, 7.901 contienen una calificación activa. Tras la agregación, el panel cuenta con 4.160 combinaciones entidad-año, de las cuales 3.558 presentan al menos un rating disponible, lo que representa aproximadamente el 85,5 % del panel potencial.

Entre las observaciones con alguna calificación, 832 disponen de una única agencia, 1.109 de dos y 1.617 de las tres. Esto equivale aproximadamente al 23,4 %, 31,2 % y 45,4 %, respectivamente. Las diferencias entre agencias no se pierden con esta agregación, ya que se conservan adicionalmente variables de dispersión como el mínimo, máximo, rango y desviación típica de las puntuaciones.

Ese último añadido me parece especialmente bueno, porque responde a una posible crítica: “si haces la media, estás ocultando el desacuerdo entre agencias”. Tú puedes decir que no, porque la media es tu medida agregada, pero el desacuerdo queda recogido en `rating_score_min`, `rating_score_max`, `rating_score_range` y `rating_score_std`.

A.7 CREACIÓN DE LA VARIABLE OBJETIVO

La variable objetivo se obtuvo relacionando el rating medio del año t+1 con los fundamentales observados en t. En la integración definitiva se renombró el año del panel de ratings como rating_year y se calculó predictor_year = rating_year - 1. La unión se efectuó entre iso3-year de los predictores e iso3-predictor_year de los ratings.

$$X(i,t) \rightarrow \text{rating_score_mean_t1}(i,t+1)$$

Se comprobó que rating_year coincidiera exactamente con year + 1 y que no existieran duplicados por entidad y año predictor. La variable target_available_t1 identifica las filas con objetivo. Esta condición reduce el panel de 5.425 a 3.434 observaciones, equivalentes al 63,3 %, y de 217 a 159 entidades.

El rating observado en t se incorporó por separado como rating_score_mean_t. Está disponible en 3.374 filas del panel 2000-2024; existen 3.373 observaciones con rating en t y t+1. A partir de ellas se calcula rating_change_t1 = rating_score_mean_t1 - rating_score_mean_t. Un valor positivo indica mejora, uno negativo deterioro y cero ausencia de cambio.

A.7.1 DIVISIÓN TEMPORAL DE LA MUESTRA

Muestra	Años X	Años del rating	Observaciones	Entidades	Finalidad
Entrenamiento	2000-2018	2001-2019	2.497	155	Ajuste de modelos y preprocesamiento
Validación	2019-2021	2020-2022	466	156	Selección de modelo e hiperparámetros
Test	2022-2024	2023-2025	471	158	Evaluación final una sola vez

Tabla A23 División cronológica de la muestra final

A.8 RESULTADO FINAL Y TRAZABILIDAD

La base `country_risk_model_ready_2000_2024.csv` conserva las 3.434 observaciones con rating futuro disponible, los identificadores, los ratings, las variables auxiliares, las variables originales y las 29 derivadas. El fichero contiene 108 columnas, de las que 71 constituyen la entrada del modelo fundamental. La versión previa `country_risk_panel_prepared_2000_2024.csv` mantiene las 5.425 combinaciones y permite rehacer la selección sin perder información.

La estructura final preserva tres niveles de trazabilidad: los ficheros brutos descargados, los paneles procesados por bloque y la base integrada. Los archivos de cobertura, errores y auditoría permiten revisar fechas no reconocidas, códigos geográficos, duplicados, porcentajes de ausencia, rangos y procedencia de los ratings sin repetir toda la descarga.

En conclusión, la variable objetivo representa el rating soberano medio vigente en el año posterior al de los predictores. La limpieza distingue entre ausencia de calificación y default, no completa retrospectivamente los ratings y respeta el orden temporal de la información. La imputación y el resto del preprocesamiento se estiman únicamente después de realizar la división cronológica, manteniendo los conjuntos de validación y test completamente fuera del ajuste.

Esta organización permite reconstruir cada observación de la base final desde su fuente original y comprobar las transformaciones aplicadas en cada etapa del proceso. La separación entre datos brutos, paneles intermedios y base de modelización evita que las decisiones de limpieza, agregación o selección de variables modifiquen los archivos originales y facilita la reproducción del análisis.

Asimismo, la construcción de la base se mantiene separada del proceso de entrenamiento de los modelos. La selección temporal, la imputación y las transformaciones dependientes de la muestra se realizan posteriormente dentro del procedimiento de modelización, evitando incorporar información procedente de validación o test en las etapas de ajuste.

De este modo, `country_risk_model_ready_2000_2024.csv` constituye el punto de partida común para los distintos modelos analizados, mientras que los ficheros anteriores permiten auditar o modificar cualquier decisión de construcción sin necesidad de reconstruir el conjunto de datos desde cero.