

ANEXO II

DESARROLLO, SELECCIÓN Y DIAGNÓSTICO DE LOS MODELOS



UNIVERSIDAD
COMPLUTENSE
MADRID

Máster Big Data, Data Science & Inteligencia Artificial
2025-2026

Mónica López Alonso

ANEXO II

DESARROLLO, SELECCIÓN Y DIAGNÓSTICO DE LOS MODELOS

Este anexo recoge de forma ampliada el proceso de estimación, selección y diagnóstico de los modelos utilizados para predecir el rating soberano del periodo $t+1$ a partir de información disponible en t . Su finalidad es complementar la metodología y los resultados presentados en el cuerpo principal del trabajo, incorporando el detalle de los hiperparámetros seleccionados, las métricas obtenidas durante la fase de validación, el análisis del sobreajuste y los principales elementos utilizados para interpretar los modelos.

La selección se realizó respetando la estructura temporal de la base de datos: el periodo 2000-2018 se utilizó para entrenamiento, 2019-2021 para validación y 2022-2024 quedó reservado para la evaluación final. El conjunto de test no intervino, por tanto, en la selección de algoritmos ni de hiperparámetros.

B.1. REGRESIÓN LINEAL OLS

La regresión lineal constituye el primer modelo utilizado como referencia para estudiar la relación entre los fundamentales y el rating soberano futuro. Además de su utilidad predictiva, este modelo permite analizar directamente el signo, magnitud y significatividad estadística de los coeficientes, y ofrecer una primera aproximación a las variables más relevantes para predecir la variable objetivo.

La especificación inicial presentaba un elevado grado de multicolinealidad, por lo que se realizó un proceso de depuración eliminando dependencias lineales exactas y reduciendo los factores de inflación de la varianza por debajo de 10 (VIF). Para la especificación final se estimó una regresión OLS con errores estándar robustos agrupados por país, con el objetivo de tener en cuenta la dependencia existente entre las observaciones correspondientes a un mismo Estado. La regresión estimada sobre el conjunto de entrenamiento presenta un $R^2 = 0,862$ y un R^2 ajustado = 0,858.

De las 57 variables explicativas incluidas en esta especificación, 15 presentan significatividad estadística al 5 %, 11 al 1 % y 5 al 0,1 %.

Variable	Coefficiente	Error estándar	p-valor	Significatividad
gdp_ppp_constant_2021_intl_usd	7,5552	1,1395	<0,001	***
government_debt_pct_gdp	-4,4394	0,6814	<0,001	***
government_effectiveness_estimate	13,8367	2,1601	<0,001	***
fdi_net_inflows_pct_gdp	0,0570	0,0141	<0,001	***
never_default_history_dummy	10,3027	2,6920	<0,001	***
reserves_months_imports	1,1917	0,3923	0,0024	**
high_inflation_dummy	-4,4762	1,5265	0,0034	**
electoral_democracy_index	4,9191	1,6995	0,0038	**
government_expenditure_change	0,3952	0,1385	0,0043	**
investment_pct_gdp	1,5001	0,5373	0,0052	**
sovereign_debt_in_default_usd_mn	-3,2870	1,2231	0,0072	**
fiscal_balance_pct_gdp	0,8295	0,3452	0,0163	*
gdp_per_capita_ppp_constant_2021_intl_usd	4,6571	1,9933	0,0195	*
exports_growth_pct	-0,3227	0,1520	0,0337	*
government_changes_previous_5y	-1,1878	0,5976	0,0468	*

Tabla B.1. Variables estadísticamente significativas en la regresión OLS

* $p < 0,05$; ** $p < 0,01$; *** $p < 0,001$.

Los coeficientes muestran que el nivel de desarrollo económico, la calidad institucional, las reservas, la posición fiscal y la ausencia de antecedentes de default presentan asociaciones positivas con la calificación soberana. En sentido contrario, la deuda pública, la deuda soberana en situación de default, los episodios de inflación elevada y una mayor frecuencia de cambios de gobierno presentan coeficientes negativos.

Estas magnitudes deben interpretarse teniendo en cuenta las transformaciones y el escalado aplicados previamente a las variables, por lo que el interés principal reside en el signo, significatividad y relevancia relativa, y no en una interpretación causal directa de cada coeficiente.




Figura B.1 Coeficientes de las variables significativas con intervalos de confianza al 95 %

Esta representación gráfica complementa la Tabla B.1 al mostrar la precisión de las estimaciones. Aunque todos los intervalos de confianza excluyen el valor cero, su amplitud evidencia que el grado de incertidumbre no es uniforme entre las variables. A partir de esta referencia lineal, se evalúan modelos regularizados para comprobar si la penalización permitía mejorar la estabilidad y la capacidad predictiva.

B.2. MODELOS REGULARIZADOS

Con el objetivo de controlar la inestabilidad de los coeficientes y estudiar alternativas a la regresión lineal, se estimaron tres modelos regularizados: [Ridge](#), [Lasso](#) y [Elastic Net](#). Los hiperparámetros fueron seleccionados utilizando exclusivamente el conjunto de validación.

Ridge aplica una penalización L2, Lasso una penalización L1 que puede reducir coeficientes exactamente a cero y Elastic Net combina ambas penalizaciones.

Para completar el análisis del ajuste, los modelos definitivos se reconstruyeron en un notebook independiente a partir de la misma matriz de entrenamiento y de los hiperparámetros previamente guardados. No se repitió la búsqueda de hiperparámetros ni se modificaron las particiones temporales utilizadas en la selección original.

Los resultados obtenidos fueron los siguientes:

El mejor valor de α para Ridge fue 12,589; para Lasso, 0,1189; mientras que Elastic Net seleccionó $\alpha = 0,1151$ y $l1_ratio = 0,99$.

Modelo	Hiperparámetros seleccionados	Train MAE	Validation MAE	RMSE valid.	R ² valid.
Ridge	$\alpha = 12,589$	5,778	7,265	10,424	0,860
Lasso	$\alpha = 0,1189$	6,168	7,167	10,586	0,855
Elastic Net	$\alpha = 0,1151$; $l1_ratio = 0,99$	6,166	7,179	10,586	0,855

Tabla B.3. Resultados de los modelos regularizados

Se pueden observar diferencias reducidas entre las tres especificaciones. Lasso obtiene el menor MAE de validación con 7.167 puntos, mientras que Ridge presenta un RMSE ligeramente menor y un R² algo superior. La diferencia entre el MAE de entrenamiento y el de validación es de 1,487 puntos en Ridge, 0,999 en Lasso y 1,013 en Elastic Net. Por tanto, los tres modelos mantienen un comportamiento relativamente estable fuera de la muestra de entrenamiento, aunque su capacidad predictiva queda por debajo de la alcanzada posteriormente por los métodos no lineales.

La principal aportación adicional de Lasso es su capacidad de selección automática de variables. De los 111 predictores disponibles, conserva 55 y elimina 56 mediante coeficientes exactamente iguales a cero, lo que supone una reducción del 50,45 % de los predictores. Elastic Net presenta un comportamiento muy similar, conservando 56 variables.

B.3. SUPPORT VECTOR REGRESSION Y RED NEURONAL

La siguiente fase incorporó dos modelos capaces de representar relaciones no lineales: [Support Vector Regression con kernel RBF](#) y una [red neuronal multicapa MLP](#).

En el caso de SVR se seleccionó una configuración con $C = 100$, $\epsilon = 2$ y $\gamma = 0,001$. La red neuronal seleccionada emplea dos capas ocultas de 50 y 25 neuronas, un parámetro de regularización $\alpha = 0,0001$ y una tasa de aprendizaje inicial de 0,001.

Modelo	Hiperparámetros seleccionados	Train MAE	Validation MAE	RMSE valid.	R ² valid.
SVR-RBF	$C=100$; $\epsilon=2$; $\gamma=0,001$	4,615	7,430	10,712	0,852
MLP	capas=(50,25); $\alpha=0,0001$; lr=0,001	2,253	6,056	8,620	0,904

Tabla B.4. Resultados de SVR y MLP

La red neuronal obtiene una mejora clara respecto a los modelos lineales y regularizados y constituye el mejor resultado de la Rama A cuando se utilizan exclusivamente variables fundamentales. Su MAE de validación se reduce hasta 6,056 y su R² aumenta hasta 0,904. El MAE de entrenamiento es de 2,253 puntos, frente a 4,615 en SVR.

La diferencia entre entrenamiento y validación asciende a 2,815 puntos en SVR y a 3,803 en la MLP. Aunque la red neuronal muestra una mayor separación entre ambas muestras, mantiene una ventaja sustancial en validación y presenta el mejor equilibrio predictivo dentro de esta rama. La MLP converge después de 245 iteraciones, con una pérdida final de 4,9762.




Figura B.2 Evolución de la función de pérdida de la MLP

La pérdida disminuye rápidamente y se estabiliza sin oscilaciones relevantes, confirmando la convergencia del entrenamiento y la utilidad de modelizar relaciones no lineales.

B.4. ÁRBOL DE DECISIÓN

El árbol de decisión constituye el primer modelo de la Rama B. A diferencia de los modelos anteriores, no requiere estandarización de las variables y puede capturar directamente relaciones no lineales e interacciones entre los fundamentales.

La búsqueda de hiperparámetros evaluó distintas combinaciones de profundidad máxima, número mínimo de observaciones requerido para realizar una división y tamaño mínimo de las hojas. La configuración seleccionada fue:

Hiperparámetro	Valor
max_depth	10
min_samples_split	10
min_samples_leaf	5
Número de hojas final	207

La configuración seleccionada obtiene un MAE de entrenamiento de 2,973 y un MAE de validación de 6,880, con un RMSE de validación de 10,677 y un R² de 0,853. El árbol final alcanza una profundidad de 10 niveles y 207 hojas.

La estructura del árbol muestra que las primeras divisiones se encuentran estrechamente vinculadas con el historial de default, especialmente years_since_last_default, y posteriormente con variables institucionales como la calidad regulatoria y la efectividad gubernamental.




Figura B.3 Primeros niveles del árbol de decisión

Tras limitar su complejidad, sigue existiendo una diferencia considerable entre entrenamiento y validación. Este comportamiento justifica la utilización posterior de métodos ensemble, capaces de combinar múltiples árboles y reducir la varianza de un árbol individual.

B.5. MODELOS ENSEMBLE Y BOOSTING

La última etapa de selección incorpora [Random Forest](#), [Extra Trees](#), [Gradient Boosting](#) y [XGBoost](#). Estos algoritmos proporcionan las mejores métricas de validación de todo el proceso.

Tabla B.5. Hiperparámetros seleccionados

Modelo	Hiperparámetros
Random Forest	n_estimators=200; max_depth=15; min_samples_leaf=1; max_features=0.5
Extra Trees	n_estimators=300; max_depth=20; min_samples_leaf=1; max_features=1.0
Gradient Boosting	n_estimators=300; learning_rate=0.075; max_depth=5; min_samples_leaf=10; subsample=0.8
XGBoost	n_estimators=500; learning_rate=0.05; max_depth=4; min_child_weight=1; subsample=0.8; colsample_bytree=0.8

Tabla B.6. Comparación de los modelos ensemble

Modelo	Train MAE	Validation MAE	RMSE valid.	R ² valid.	Gap MAE
Extra Trees	0,067	4,879	7,800	0,921	4,812
Gradient Boosting	1,040	4,942	7,381	0,930	3,902
Random Forest	1,245	5,038	7,687	0,924	3,793
XGBoost	1,449	5,122	7,476	0,928	3,673

Extra Trees obtiene el menor MAE de validación, mientras que Gradient Boosting presenta el menor RMSE y el mayor R². Random Forest se mantiene muy próximo a ambos modelos.




Figura B.4 MAE de entrenamiento frente a MAE de validación

Extra Trees obtiene el menor MAE de validación, pero su error prácticamente nulo en entrenamiento evidencia un mayor sobreajuste. Random Forest presenta un MAE de validación ligeramente superior, aunque reduce considerablemente la diferencia entre ambas muestras.




Figura B.5. Predicciones fuera del rango de la variable objetivo [0,100]

La elección del modelo definitivo no se realizó atendiendo exclusivamente al menor MAE. Extra Trees pasa de un MAE de 0,067 en entrenamiento a 4,879 en validación, un incremento de aproximadamente 4,81 puntos. Random Forest pasa de 1,245 a 5,038, con una diferencia menor, de aproximadamente 3,79 puntos.

Además, Random Forest y Extra Trees mantienen todas sus predicciones dentro de la escala válida de 0 a 100, mientras que Gradient Boosting y XGBoost generan respectivamente 6 y 5 observaciones fuera del intervalo.

Por tanto, la diferencia de 0,159 puntos de MAE favorable a Extra Trees se consideró insuficiente para compensar su mayor grado de sobreajuste. Random Forest fue seleccionado como modelo definitivo por combinar una capacidad predictiva muy próxima a los mejores resultados, mayor estabilidad entre entrenamiento y validación y predicciones compatibles con la escala utilizada.

Este análisis permite justificar que la selección final no responde únicamente a la métrica mínima de validación, sino al equilibrio entre precisión, capacidad de generalización y coherencia de las predicciones.

B.6. DIAGNÓSTICO DEL RANDOM FOREST DEFINITIVO

Una vez seleccionado Random Forest, el modelo se reestimó combinando las muestras de entrenamiento y validación, utilizando toda la información disponible entre 2000 y 2021. El conjunto de test, correspondiente a las variables de 2022-2024 y a los ratings objetivo de 2023-2025, se utilizó una única vez para la evaluación final.

La configuración definitiva mantiene los hiperparámetros seleccionados durante la fase de validación:

- `n_estimators` = 200,
- `max_depth` = 15,
- `min_samples_leaf` = 1,
- `max_features` = 0,5.

El modelo obtiene un MAE de 4,988, un RMSE de 7,654 y un R^2 de 0,928 sobre el conjunto de test. El MAE de la muestra utilizada para el entrenamiento final es 1,249.

B.6.1. DISTRIBUCIÓN DE LOS RESIDUOS

El residuo se define como la diferencia entre el valor real y la predicción, $e_i = y_i - \hat{y}_i$. La distribución se encuentra concentrada alrededor de cero, aunque presenta una cola negativa asociada a algunas observaciones en las que el modelo sobreestima considerablemente el rating observado.




Figura b.6 histograma de residuos

El residuo medio es -2,484 y la mediana -0,680. La diferencia entre ambas medidas indica que el sesgo negativo está condicionado fundamentalmente por un número relativamente reducido de errores extremos.




Figura b.7 aquí — boxplot de residuos

La distribución de los residuos se concentra alrededor de cero, aunque presenta una mayor dispersión hacia valores negativos y varios valores extremos. Estos casos corresponden principalmente a observaciones en las que el modelo sobreestima el rating real. La asimetría observada indica que los errores de mayor magnitud no se distribuyen de forma completamente uniforme, aunque afectan a un número reducido de observaciones.




Figura b.8 aquí — residuos frente a predicción

Las predicciones se sitúan mayoritariamente próximas a la diagonal de igualdad, lo que confirma un buen ajuste del modelo a lo largo de la escala de ratings. No obstante, en los niveles más bajos se aprecia cierta tendencia a sobreestimar la calificación, mientras

que en los valores más elevados las predicciones tienden a concentrarse ligeramente por debajo del valor real. Este comportamiento refleja una moderada regresión hacia valores centrales, característica de los modelos basados en agregación de árboles.

En conjunto, el diagnóstico no muestra un sesgo generalizado en las predicciones, aunque identifica una menor precisión en determinadas observaciones extremas, aspecto que debe tenerse en cuenta al interpretar individualmente las estimaciones del modelo.

B.6.2. ESTABILIDAD TEMPORAL

El error aumenta moderadamente durante el periodo de test:

Año del rating predicho	MAE
2023	4,549
2024	5,079
2025	5,331

El incremento es progresivo pero limitado, manteniéndose el MAE en torno a cinco puntos durante todo el periodo.




Figura B.9 MAE por año del rating predicho

La evolución anual muestra un aumento gradual del error, desde un MAE de 4,549 puntos en 2023 hasta 5,331 en 2025. No obstante, el incremento es reducido y no se observan deterioros bruscos entre años consecutivos. Este comportamiento sugiere una estabilidad temporal razonable del modelo durante el periodo de test, aunque con una ligera pérdida de precisión a medida que las predicciones se alejan del periodo utilizado para el entrenamiento.

B.6.3. OBSERVACIONES CON MAYOR ERROR

País	Rating objetivo	Rating real	Predicción	Error absoluto
Rusia	2025	13,33	47,51	34,17
Rusia	2024	13,33	47,13	33,79
Bahamas	2025	35,00	67,32	32,32
Rusia	2023	13,33	43,58	30,25
Bahamas	2024	35,00	64,44	29,44
Bielorrusia	2025	0,00	25,69	25,69
Omán	2023	48,33	72,65	24,31
Ghana	2024	0,00	24,30	24,30
Omán	2024	50,00	74,14	24,14
Bielorrusia	2023	0,00	24,08	24,08

Tabla B.9. Principales errores absolutos del modelo definitivo

Los mayores errores se concentran especialmente en Rusia, Bahamas, Bielorrusia, Omán y Ghana. En muchos de estos casos el modelo asigna una calidad crediticia superior a la finalmente observada.

Este comportamiento resulta coherente con el sesgo negativo observado en los residuos y pone de manifiesto una de las principales limitaciones del enfoque: determinados shocks económicos, financieros o geopolíticos producidos entre t y $t+1$ no pueden estar completamente reflejados en los fundamentales observados en t .

	country	year	rating_year	rating_score_mean_t1	prediction	absolute_error
2785	Russian Federation	2024	2025	13.33	47.51	34.17
2784	Russian Federation	2023	2024	13.33	47.13	33.79
371	Bahamas, The	2024	2025	35.00	67.32	32.32
2783	Russian Federation	2022	2023	13.33	43.58	30.25
370	Bahamas, The	2023	2024	35.00	64.44	29.44
412	Belarus	2024	2025	0.00	25.69	25.69
2497	Oman	2022	2023	48.33	72.65	24.31
1231	Ghana	2023	2024	0.00	24.30	24.30
2498	Oman	2023	2024	50.00	74.14	24.14
410	Belarus	2022	2023	0.00	24.08	24.08
1617	Italy	2023	2024	58.33	82.07	23.73
411	Belarus	2023	2024	0.00	23.51	23.51
2941	San Marino	2024	2025	45.00	68.25	23.25
1616	Italy	2022	2023	58.33	80.86	22.52
346	Bahrain	2024	2025	31.67	53.72	22.06

Figura B.10 Países con mayor error absoluto de predicción

Los mayores errores absolutos se concentran en un número reducido de observaciones y afectan principalmente a países con calificaciones soberanas muy bajas o situaciones especialmente adversas. Destacan los casos de la Federación Rusa, Bahamas y Bielorrusia, donde la predicción se sitúa sensiblemente por encima del rating observado.

Este patrón confirma lo observado en el análisis de residuos: los errores más extremos son mayoritariamente negativos, lo que indica una tendencia del modelo a sobreestimar determinadas calificaciones situadas en la parte baja de la escala. En estos casos, los fundamentales incluidos en el modelo no captan completamente algunos factores excepcionales o episodios específicos que afectan a la valoración crediticia.

Aun así, estos errores representan casos concretos y no el comportamiento general del modelo, cuyas predicciones se mantienen próximas a los valores observados para la mayor parte de la muestra.

Se complementa también con la tabla de los 10 países con mayor MAE medio, evitando así utilizar únicamente los error individuales más extremos.




Figura B.10.1 Diez países con mayor MAE medio en el conjunto de test.

El análisis por país confirma y amplía los resultados obtenidos al estudiar las observaciones con mayor error absoluto. La **Federación Rusa** presenta el mayor MAE medio, con 32,74 puntos, y aparece además en los tres años entre los mayores errores individuales, lo que indica que no se trata de una desviación puntual, sino de una dificultad persistente del modelo para representar su calificación durante el periodo de test. Un comportamiento similar se observa en **Bahamas, Bielorrusia y Omán**, que también aparecen repetidamente entre las observaciones con mayor error.

La comparación entre ambos análisis permite distinguir los errores excepcionalmente elevados de aquellos que se mantienen de forma sistemática. Países como **Italia, Baréin, San Marino y Ghana** aparecen en ambos resultados, aunque con errores

medios inferiores, mientras que **Ucrania y Puerto Rico** entran entre los países con mayor MAE medio sin figurar entre las observaciones individuales más extremas mostradas anteriormente. Esto indica que pueden presentar desviaciones relevantes de forma recurrente, aunque ninguna de ellas alcance por sí sola los mayores errores de la muestra.

En conjunto, los resultados muestran que una parte importante de los errores extremos está concentrada en un grupo reducido de países. Esto refuerza la evidencia anterior de que el modelo presenta mayores dificultades en determinados casos específicos, especialmente cuando la calificación observada se aleja de la que cabría esperar a partir de los fundamentales incluidos en el modelo.

Además, varios de estos países presentan ratings bajos durante el periodo analizado, en línea con la mayor pérdida de precisión observada en el tramo inferior de la escala de calificación.

B.6.4. ERROR SEGÚN EL NIVEL DE RATING




Figura B.11 MAE por tramo de rating

El error de predicción varía de forma notable según el nivel de rating observado. El tramo más bajo, entre 0 y 20 puntos, presenta el mayor MAE, con 10,69 puntos, muy por encima del resto de intervalos. A partir de ese nivel, el error se reduce de forma clara, situándose entre 4,56 y 5,02 puntos en los tramos intermedios y descendiendo hasta 2,00 puntos para los ratings comprendidos entre 80 y 100.

Este resultado muestra que el modelo ofrece una mayor precisión en las calificaciones medias y altas, mientras que encuentra mayores dificultades para estimar correctamente los niveles de riesgo soberano más extremos. Este comportamiento es coherente con el análisis de residuos y de los mayores errores individuales, donde se observaba una tendencia a sobreestimar algunas calificaciones situadas en la parte

inferior de la escala. Además, el menor número de observaciones en determinados tramos debe tenerse en cuenta al comparar los errores entre grupos.

Por tanto, aunque el rendimiento agregado del modelo es elevado, sus predicciones deben interpretarse con mayor cautela en países con ratings muy bajos.

B.7. IMPORTANCIA COMPLETA DE LAS VARIABLES

La interpretación del Random Forest se complementa mediante la importancia por permutación. A diferencia de la importancia interna del algoritmo, este procedimiento mide cuánto empeora el error predictivo cuando se altera aleatoriamente una variable, manteniendo las restantes sin modificar.

En la evaluación final, las variables con mayor importancia por permutación son la calidad regulatoria, los años transcurridos desde el último default, el PIB en PPA, la efectividad gubernamental y el historial de ausencia de default. También destacan el nivel de renta, el PIB per cápita y la deuda pública.

Pos.	Variable	Importancia
1	regulatory_quality_estimate	4,6650
2	years_since_last_default	3,4019
3	gdp_ppp_constant_2021_intl_usd	2,2300
4	government_effectiveness_estimate	2,0859
5	never_default_history_dummy	1,6885
6	income_level_High income	1,6331
7	gdp_per_capita_constant_2015_usd	1,5171
8	government_debt_pct_gdp	1,3160
9	rule_of_law_estimate	0,6651
10	gdp_per_capita_ppp_constant_2021_intl_usd	0,5466
11	net_interest_payments_pct_gdp	0,5236
12	sovereign_debt_in_default_usd_mn	0,4459
13	reserves_months_imports	0,3807
14	control_of_corruption_estimate	0,2883
15	gross_savings_pct_gdp	0,2406
16	current_account_3y_mean	0,2311
17	electoral_democracy_index	0,2092
18	voice_accountability_estimate	0,1649
19	default_previous_10y	0,1640
20	missingindicator_inflation_cpi_pct	0,1505

Tabla B.10. Principales variables según permutation importance

Estos resultados muestran que la predicción no depende de un único bloque de información, sino de la combinación de factores institucionales, económicos, fiscales y vinculados al historial crediticio. Las mayores contribuciones proceden de la calidad regulatoria, los años transcurridos desde el último default, el PIB en PPA y la efectividad gubernamental, lo que pone de manifiesto el peso conjunto de la calidad institucional, el nivel de desarrollo y la trayectoria de solvencia soberana.

También presentan una relevancia destacada variables como la renta alta, el PIB per cápita, la deuda pública y el Estado de derecho. A partir de estas posiciones, la importancia disminuye de forma progresiva, aunque siguen apareciendo indicadores relacionados con reservas, ahorro, cuenta corriente, democracia y otras dimensiones institucionales y fiscales.

Entre las variables más relevantes se combinan indicadores institucionales, de desarrollo económico, fiscales y vinculados al historial crediticio.




Figura b.12 Principales variables del Random Forest definitivo según la importancia por permutación.

La importancia por permutación confirma que la capacidad predictiva del modelo se concentra en un grupo reducido de variables. La calidad regulatoria presenta con diferencia la mayor importancia, seguida por los años transcurridos desde el último default, el PIB en PPA, la efectividad gubernamental y el indicador de ausencia de antecedentes de impago. También destacan el nivel de renta, el PIB per cápita y la deuda pública.

En términos económicos, los resultados muestran que el rating soberano estimado depende de una combinación de factores institucionales, de desarrollo económico, fiscales y de historial crediticio. Las variables institucionales ocupan posiciones especialmente elevadas, mientras que las relacionadas con el default aparecen entre los principales determinantes, lo que refleja la persistencia de la trayectoria crediticia de cada país.

A partir de las primeras posiciones, la contribución marginal disminuye de forma considerable. Variables como reservas, saldo por cuenta corriente, ahorro, desempleo o saldo fiscal siguen aportando información, pero su efecto sobre el error predictivo es sensiblemente menor que el de las variables principales.

Esta medida debe interpretarse como **importancia predictiva y no como efecto causal**. Además, cuando existen variables correlacionadas, la información puede repartirse entre ellas, por lo que una importancia individual reducida no implica necesariamente que la variable carezca de relación con el riesgo soberano.




Figura b.13 Principales variables según la importancia interna del Random Forest definitivo.

La importancia interna del Random Forest presenta una jerarquía similar, aunque no idéntica, a la obtenida mediante permutación. En este caso, `years_since_last_default` ocupa la primera posición, seguida de `never_default_history_dummy`, el nivel de renta, la calidad regulatoria y el PIB per cápita. También destacan la efectividad gubernamental, el PIB en PPA y la deuda pública.

La comparación entre ambas medidas muestra una elevada coincidencia en las variables que concentran mayor capacidad predictiva, especialmente las relacionadas con el historial de default, la calidad institucional, el nivel de desarrollo económico y la posición fiscal. Las diferencias en el orden son esperables, ya que ambas métricas miden la relevancia de las variables de forma distinta.

La importancia interna se basa en la reducción de impureza producida por cada variable en las divisiones de los árboles, mientras que la importancia por permutación evalúa cuánto empeora el error de predicción cuando se altera aleatoriamente una variable. Por este motivo, la segunda ofrece una medida más directamente vinculada al rendimiento predictivo fuera de muestra, mientras que la primera permite interpretar cómo utiliza internamente el bosque las variables durante su construcción.

En conjunto, ambas aproximaciones refuerzan la misma conclusión: la predicción del rating soberano se apoya principalmente en una combinación de trayectoria crediticia, calidad institucional, desarrollo económico y situación fiscal, sin depender exclusivamente de un único grupo de indicadores.

La importancia interna puede favorecer variables continuas o con mayor número de posibles puntos de corte, por lo que su interpretación debe realizarse de forma complementaria a la importancia por permutación.




Figura b.14 Comparación normalizada entre la importancia por permutación y la importancia interna del Random Forest definitivo.

La comparación conjunta confirma que ambas medidas conducen a una interpretación consistente del modelo. Aunque existen diferencias en la intensidad relativa asignada a cada variable, las posiciones superiores se concentran en los mismos grupos de factores y no se observa un cambio sustancial en la estructura general de importancia.

Las discrepancias entre ambas métricas se concentran principalmente en el peso relativo de determinadas variables. La importancia por permutación otorga mayor relevancia a algunos indicadores institucionales y económicos, mientras que la importancia interna concede un peso comparativamente superior a las variables asociadas al historial de default. Aun así, estas diferencias no alteran la conclusión general sobre los principales bloques de información utilizados por el modelo.

Por tanto, la comparación de ambas medidas refuerza la estabilidad de la interpretación obtenida y reduce la dependencia de una única técnica para identificar las variables más relevantes.