

ANEXO III

PERSISTENCIA Y MODELIZACIÓN DEL CAMBIO DE RATING



UNIVERSIDAD
COMPLUTENSE
MADRID

Máster Big Data, Data Science & Inteligencia Artificial
2025-2026

Mónica López Alonso

ANEXO III

PERSISTENCIA Y MODELIZACIÓN DEL CAMBIO DE RATING

Este anexo desarrolla el análisis complementario de la dinámica de las calificaciones soberanas. El modelo principal del trabajo estima el nivel futuro del rating a partir de variables fundamentales, pero la elevada estabilidad temporal de las calificaciones hace necesario comprobar por separado si esos mismos factores permiten anticipar una revisión y su dirección.

El punto de partida es el benchmark de persistencia. En la predicción del nivel, mantener el rating vigente como estimación del año siguiente alcanza un MAE de 1,505 y un R^2 de 0,977. Sin embargo, cuando el análisis se restringe a las 137 observaciones de validación en las que el rating cambia, el MAE aumenta a 5,097. En esa submuestra, la regresión que combina fundamentales y rating previo reduce ligeramente el MAE hasta 4,951. La diferencia es pequeña, pero indica que los fundamentales pueden contener información adicional precisamente en los episodios de revisión.

Muestra de validación	Observaciones	MAE	RMS E	R^2
Persistencia en la muestra completa	464	1,505	4,209	0,977
Persistencia cuando cambia el rating	137	5,097	7,746	0,897
Fundamentales y rating previo cuando cambia	137	4,951	7,736	0,897

Tabla C.0 Tabla resumen persistencia

A partir de esta evidencia se formula un problema de clasificación con tres resultados posibles: deterioro, ausencia de cambio y mejora. La evaluación se apoya principalmente en balanced accuracy, F1 macro y recall por clase, ya que la accuracy global puede resultar engañosa cuando predomina la estabilidad.

C.1. DISTRIBUCIÓN DE LOS CAMBIOS

La composición de la variable objetivo confirma un desequilibrio marcado. En test, 348 de las 469 observaciones permanecen sin cambios, 83 mejoran y 38 empeoran. Por tanto, la clase estable representa el 74,2 % de la muestra, frente al 17,7 % de mejoras y el 8,1 % de deterioros.




Figura C.1. Distribución de las categorías de cambio en el conjunto de test

Categoría	Observaciones	Porcentaje
Sin cambio	348	74,2 %
Mejora	83	17,7 %
Deterioro	38	8,1 %

Tabla C.1. Distribución de las categorías de cambio en el conjunto de test

La distribución no es constante entre periodos. En entrenamiento, el 67,50 % de las observaciones no cambia; en validación, la proporción aumenta al 70,47 %. Además, validación concentra más deterioros que mejoras, mientras que test presenta el patrón contrario. Esta variación temporal eleva la dificultad de generalización y justifica mantener el orden cronológico de las muestras.

Este desequilibrio debe tenerse en cuenta al evaluar los modelos de clasificación. Una elevada proporción de observaciones sin cambio puede producir resultados aparentemente favorables si se utiliza únicamente la exactitud global, aun cuando el modelo identifique mal las mejoras y, especialmente, los deterioros. Por este motivo, la evaluación posterior se apoya en métricas sensibles al rendimiento de todas las clases, como la balanced accuracy y el F1 macro.

La clase de deterioro constituye además el grupo más reducido, con solo 38 observaciones en test, por lo que sus métricas presentan una mayor sensibilidad a pequeños cambios en el número de aciertos y errores. Esta limitación debe considerarse al interpretar los resultados desagregados por categoría.

C.2. BENCHMARK DE PERSISTENCIA

El benchmark más simple consiste en predecir siempre la clase «sin cambio». En validación alcanza una accuracy de 0,705 al acertar todas las observaciones de la clase mayoritaria. Sin embargo, su balanced accuracy es 0,333 y su F1 macro 0,276; además, los recalls de mejora y deterioro son nulos.

Modelo	Accuracy	Balanced accuracy	F1 macro	Recall deterioro	Recall estable	Recall mejora
Siempre sin cambio	0,705	0,333	0,276	0,000	1,000	0,000

Tabla C.2 Benchmark de persistencia. Resultados

Este resultado muestra por qué la accuracy no puede utilizarse como criterio principal. Un modelo sin capacidad para detectar revisiones alcanza una tasa aparente de acierto elevada únicamente por la persistencia de la serie. Las métricas equilibradas obligan a valorar el rendimiento sobre las tres clases.

El benchmark de persistencia establece así una referencia mínima especialmente exigente en un problema con fuerte desequilibrio entre clases. Superarlo requiere no solo mantener un nivel razonable de acierto global, sino mejorar de forma efectiva la identificación de mejoras y deterioros. Por este motivo, los modelos posteriores se comparan principalmente mediante balanced accuracy, F1 macro y los recalls específicos de cada clase.

C.3. CLASIFICACIÓN DIRECTA

La primera estrategia estima directamente las tres categorías. Se compararon regresión logística, árbol de decisión, Random Forest, SVM, XGBoost y regresión logística ordinal. También se ensayaron configuraciones en dos etapas durante la comparación inicial. Los pesos de clase se incorporaron cuando el algoritmo lo permitía.

Modelo	Accura cy	Balanced accuracy	F1 macro	Rec. deterioro	Rec. estable	Rec. mejora
SVM balanceada	0,517	0,505	0,442	0,632	0,502	0,381
Dos etapas XGBoost	0,586	0,470	0,447	0,347	0,682	0,381
Dos etapas Random Forest	0,476	0,468	0,408	0,589	0,459	0,357
Logística balanceada	0,446	0,461	0,391	0,589	0,413	0,381
Random Forest balanceado	0,422	0,439	0,368	0,600	0,382	0,333
Árbol balanceado	0,321	0,437	0,306	0,505	0,235	0,571
Logística	0,683	0,424	0,433	0,221	0,884	0,167
Regresión ordinal	0,662	0,345	0,326	0,137	0,899	0,000
Benchmark	0,705	0,333	0,276	0,000	1,000	0,000

Tabla C.3. Resultados modelos

La SVM consigue la mayor balanced accuracy de la comparación inicial, 0,505, pero su accuracy baja a 0,517. La regresión logística sin ponderación alcanza una accuracy de 0,683, aunque clasifica correctamente solo el 22,1 % de los deterioros y el 16,7 % de las mejoras. De nuevo, el acierto global favorece los modelos que concentran sus predicciones en la clase estable.

La regresión ordinal tampoco resuelve el problema: obtiene un recall nulo para las mejoras y presenta avisos de convergencia. La clasificación directa confirma que existe cierta señal predictiva, pero ninguna especificación separa de forma satisfactoria las tres categorías.

En conjunto, los resultados muestran que la clasificación directa de las tres categorías presenta dificultades para identificar simultáneamente la estabilidad, las mejoras y los deterioros. El desequilibrio de clases hace que los modelos con mayor accuracy tiendan a favorecer la categoría «sin cambio», mientras que las configuraciones balanceadas mejoran la detección de las clases minoritarias a costa de reducir el acierto global.

La SVM balanceada ofrece el comportamiento más equilibrado dentro de esta estrategia, aunque sus métricas siguen siendo moderadas y especialmente débiles en la identificación de mejoras. Estos resultados sugieren que tratar las tres categorías como un único problema multiclase puede no ser la formulación más adecuada. Por ello, se plantea a continuación una estrategia en dos etapas, separando primero la detección de cambio frente a estabilidad y, posteriormente, la dirección del cambio entre mejora y deterioro.

C.4. PONDERACIÓN DE CLASES Y SELECCIÓN

La ponderación de clases aumenta la sensibilidad hacia mejoras y deterioros, aunque reduce la accuracy global. En Random Forest se exploraron combinaciones de número de árboles, profundidad, tamaño mínimo de hoja y número de variables candidatas. La mejor clasificación directa alcanzó una balanced accuracy de 0,478 y un F1 macro de 0,463, frente a 0,333 y 0,276 del benchmark.

Parámetro	Valor seleccionado
Número de árboles	500
Profundidad máxima	15
Mínimo de observaciones por hoja	1
Variables candidatas	50 %
Ponderación	Clases balanceadas

Tabla C.4. Selección de parámetros

El modelo directo identifica el 43 % de los deterioros, el 67 % de las observaciones estables y el 33 % de las mejoras en validación. Aunque supera con claridad el benchmark en las métricas equilibradas, todavía confunde una parte importante de las revisiones con ausencia de cambio. Esta limitación motivó separar la detección de la revisión y su dirección.

La selección de esta configuración se realizó priorizando las métricas equilibradas frente a la accuracy, dado el fuerte desbalance entre las tres categorías. Aunque la ponderación de clases mejora la sensibilidad hacia mejoras y deterioros, persiste una pérdida importante de información al tratar simultáneamente la estabilidad y la dirección del cambio dentro de un único problema multiclase.

En particular, la dificultad para identificar correctamente una parte relevante de las revisiones sugiere que la primera cuestión que debe resolver el modelo no es directamente si el rating mejora, empeora o permanece estable, sino **si se producirá algún cambio**. Una vez detectada una revisión, puede abordarse de forma separada su dirección. Esta evidencia constituye la motivación principal para plantear la estrategia de clasificación en dos etapas desarrollada a continuación.

C.5. SISTEMA EN DOS ETAPAS




Figura C.2. Estructura del sistema de clasificación en dos etapas

La primera etapa determina si el rating cambia. La segunda se aplica únicamente a las observaciones clasificadas como cambio y decide si el movimiento corresponde a una mejora o un deterioro. Esta estructura distingue el problema de anticipar el momento de la revisión del problema de estimar su dirección.

C.5.1. DETECCIÓN DEL CAMBIO

Se compararon Random Forest, XGBoost y Extra Trees. El mejor Extra Trees alcanzó en validación una balanced accuracy de 0,632, un F1 de la clase cambio de 0,507 y un recall de cambio de 0,664. Superó a Random Forest y XGBoost en el criterio principal, por lo que se seleccionó para la primera etapa.

Modelo de la etapa 1	Accuracy	Balanced accuracy	F1 cambio	Recall cambio
Random Forest	0,586	0,613	0,490	0,679
XGBoost	0,647	0,607	0,461	-
Extra Trees	0,619	0,632	0,507	0,664
Extra Trees con variables dinámicas	0,616	0,622	0,494	0,635

Tabla C.5. comparación modelos en la primera etapa

La incorporación de variaciones anuales de los fundamentales no mejoró el resultado. La balanced accuracy descendió a 0,622 y el recall de cambio a 0,635, por lo que se mantuvo la especificación con los niveles originales.

C.5.2. DIRECCIÓN DEL CAMBIO

La segunda etapa se ajustó solo con observaciones que presentaban una revisión. Random Forest obtuvo una balanced accuracy de 0,670 y un F1 macro de 0,665. Clasificó correctamente 73 de los 95 deterioros y 24 de las 42 mejoras de validación, equivalentes a recalls del 76,8 % y el 57,1 %, respectivamente. La dirección puede estimarse con mayor precisión que la aparición del cambio.

El rendimiento global del sistema queda condicionado por la primera etapa, ya que una revisión clasificada erróneamente como «sin cambio» no alcanza la segunda fase y, por tanto, no puede recuperarse posteriormente. En consecuencia, aunque la dirección de las revisiones puede estimarse con mayor precisión, la principal dificultad continúa siendo anticipar correctamente su aparición. La evaluación final del sistema debe considerar, por ello, tanto el comportamiento individual de cada etapa como su funcionamiento conjunto sobre las tres categorías originales.

C.5.3. RESULTADOS CONJUNTOS EN VALIDACIÓN




Figura C.3. Matriz de confusión del sistema definitivo en validación

Clase	Precisión	Recall	F1	Soporte
Deterioro	0,31	0,45	0,37	95
Sin cambio	0,81	0,60	0,69	327
Mejora	0,26	0,52	0,35	42
Promedio macro	0,46	0,53	0,47	464

Tabla C.5. tabla complementaria a figura

El sistema definitivo combina Extra Trees en la primera etapa y Random Forest en la segunda. En validación obtiene una balanced accuracy de 0,525 y un F1 macro de 0,469. Detecta el 45,3 % de los deterioros, el 59,9 % de los casos sin cambio y el 52,4 % de las mejoras. La mejora frente a la clasificación directa es moderada, pero el comportamiento entre clases resulta más equilibrado.

La matriz de confusión muestra que los errores no se distribuyen de forma uniforme. La principal dificultad continúa siendo separar las revisiones de los casos estables: 38 deterioros y 8 mejoras se clasifican como «sin cambio», mientras que 131 observaciones realmente estables se asignan incorrectamente a alguna dirección de cambio. Además, las precisiones de deterioro y mejora, 0,31 y 0,26 respectivamente, indican que una parte importante de las revisiones predichas son falsas alarmas. Por tanto, el sistema incrementa la sensibilidad hacia las clases minoritarias respecto al benchmark de persistencia, pero lo hace a costa de una menor precisión en la identificación de los cambios.

En conjunto, la estrategia en dos etapas proporciona una clasificación más equilibrada entre las tres categorías, aunque confirma que **anticipar la existencia de una revisión sigue siendo más difícil que determinar su dirección una vez producido el cambio.**

C.6. EVALUACIÓN FINAL Y CONCLUSIÓN




Figura C.4. Matriz de confusión del sistema definitivo en test

Clase	Precision	Recall	F1	Soporte
Deterioro	0,16	0,32	0,21	38
Sin cambio	0,84	0,64	0,72	348
Mejora	0,37	0,59	0,46	83
Promedio macro	0,46	0,51	0,46	469

Tabla C.5. Métricas de clasificación por clase del sistema definitivo en test

En test, el modelo alcanza una balanced accuracy de 0,514 y un F1 macro de 0,465, valores muy próximos a los obtenidos en validación. La capacidad predictiva se mantiene fuera de muestra, aunque el rendimiento por clase es desigual. El sistema identifica el 63,5 % de los casos sin cambio y el 59,0 % de las mejoras, pero solo el 31,6 % de los deterioros.

Muestra	Balanced accuracy	F1 macro	Recall deterioro	Recall estable	Recall mejora
Validación	0,525	0,469	0,453	0,599	0,524
Test	0,514	0,465	0,316	0,635	0,590

Tabla C.5. Comparación del rendimiento del sistema definitivo en validación y test

La comparación entre validación y test muestra una elevada estabilidad de las métricas agregadas: la balanced accuracy pasa de 0,525 a 0,514 y el F1 macro de 0,469 a 0,465. Por tanto, no se observa un deterioro generalizado del rendimiento fuera de muestra. La principal diferencia se concentra en la clase deterioro, cuyo recall desciende del 45,3 %

al 31,6 %, mientras que mejora la detección de los casos estables y de las mejoras. Este resultado confirma que la principal limitación del sistema sigue siendo la anticipación de los deterioros, especialmente al tratarse de la clase menos representada en test.

La proximidad de las métricas agregadas en ambas muestras indica que el comportamiento observado en validación se mantiene razonablemente fuera de muestra, sin evidencias de una pérdida generalizada de capacidad predictiva.

En conjunto, la estrategia en dos etapas ofrece un comportamiento más equilibrado que el benchmark de persistencia y mantiene resultados similares entre validación y test. Sin embargo, la detección de deterioros continúa siendo la principal limitación del sistema, lo que pone de manifiesto la dificultad de anticipar revisiones negativas del rating únicamente a partir de la información disponible en los fundamentales.

C.6.1. LIMITACIONES Y FUTURAS LÍNEAS DE DESARROLLO

La principal limitación del sistema de clasificación es el fuerte desequilibrio entre clases, especialmente en los deterioros, que representan una proporción reducida de las observaciones disponibles. Esta escasez condiciona el aprendizaje del modelo y hace que las métricas de esta clase sean más inestables y sensibles a pequeños cambios en la muestra.

Además, la aparición de una revisión de rating depende de factores que no siempre quedan plenamente recogidos en los fundamentales anuales. Determinados episodios pueden estar asociados a acontecimientos políticos, financieros, geopolíticos o institucionales de carácter repentino, cuya incorporación requeriría información de mayor frecuencia o variables adicionales.

Otra limitación deriva de la propia estructura en dos etapas. Los errores cometidos en la primera fase se transmiten al resto del sistema, ya que una observación clasificada como «sin cambio» no puede ser posteriormente identificada como mejora o deterioro. Por ello, la capacidad global para detectar revisiones queda especialmente condicionada por el rendimiento del primer clasificador.

Como futuras líneas de desarrollo, sería conveniente ampliar el número de observaciones de cambio, incorporar variables dinámicas de mayor frecuencia y explorar modelos diseñados específicamente para eventos poco frecuentes. También podría estudiarse la calibración de probabilidades, el ajuste de umbrales de decisión y el uso de métodos sensibles al coste del error, asignando una penalización mayor a los deterioros no detectados.

Asimismo, sería de interés analizar horizontes temporales alternativos y comparar la formulación actual con enfoques de duración o riesgo de evento, en los que la cuestión central no sea únicamente si se producirá una revisión en el año siguiente, sino también cuánto tiempo transcurrirá hasta que tenga lugar.