

MODELIZACIÓN DEL RIESGO PAÍS A TRAVÉS DE LAS CALIFICACIONES CREDITICIAS SOBERANAS

Análisis de variables fundamentales y
desarrollo de una herramienta interactiva



UNIVERSIDAD
COMPLUTENSE
MADRID

Máster Big Data, Data Science & Inteligencia Artificial
2025-2026

Mónica López Alonso

ÍNDICE

1. Introducción y objetivos

- 1.1. Contexto, motivación y problema
- 1.2. Objetivos y aportaciones

2. Marco conceptual y antecedentes

- 2.1. Concepto y dimensiones del riesgo país. Calificaciones soberanas
- 2.2. Factores económicos, institucionales y políticos
- 2.3. Persistencia y cambios en los ratings
- 2.4. Antecedentes empíricos y relación con el TFG

3. Datos y construcción de la base

- 3.1. Fuentes de información
- 3.2. Unidad de análisis y variable objetivo
- 3.3. Bloques de variables explicativas
- 3.4. Integración, depuración y tratamiento de los datos
- 3.5. Descripción de la muestra final

4. Metodología

- 4.1. Diseño del problema predictivo
- 4.2. División temporal de la muestra
- 4.3. Preprocesamiento común
- 4.4. Rama A: modelos sensibles a la escala
- 4.5. Rama B: modelos basados en árboles
- 4.6. Modelos comparados
- 4.7. Métricas de evaluación
- 4.8. Benchmark de persistencia

5. Modelo seleccionado y resultados

- 5.1. Comparación de modelos
- 5.2. Selección de Random Forest
- 5.3. Evaluación final sobre el conjunto de test
- 5.4. Estabilidad temporal y análisis de errores
- 5.5. Importancia de las variables
- 5.6. Comparación con el benchmark de persistencia
- 5.7. Análisis complementario del cambio de rating

6. Herramienta interactiva

- 6.1. Funcionamiento
- 6.2. Utilidad y alcance

7. Conclusiones y limitaciones

- 7.1. Principales conclusiones
- 7.2. Cumplimiento de los objetivos
- 7.3. Limitaciones del estudio
- 7.4. Futuras líneas de investigación

8. Bibliografía

1. INTRODUCCIÓN Y OBJETIVOS

1.1 CONTEXTO , MOTIVACIÓN Y PROBLEMA

El **riesgo país** es un indicador financiero que mide la probabilidad de que un Estado no cumpla con los pagos de su deuda externa o compromisos financieros internacionales. Funciona como un termómetro de la confianza que los mercados tienen en la economía de una nación.¹

El riesgo país representa la posibilidad de que las condiciones económicas, financieras, institucionales o políticas de un Estado generen ciertos efectos adversos sobre su estabilidad y solvencia, afectando así a su capacidad para cumplir con sus obligaciones financieras. Por lo que su análisis es trivial para los gobiernos, entidades financieras e inversores, ya que evalúa la solvencia económica, comparar países y detectar situaciones de vulnerabilidad.

Una de las medidas más recurrentes para aproximar este indicador son las calificaciones crediticias emitidas por Moody's, Standard & Poor's y Fitch; las cuales resumen la valoración de estas agencias sobre la capacidad y disposición de un estado para asumir sus compromisos financieros a través de la combinación de factores macroeconómicos, fiscales, externos, institucionales y políticos. Y es que esta es una de sus características claves del riesgo país, su multidimensionalidad.

Por ello en este trabajo se aplica un enfoque conjunto, basado en la construcción de una base de datos de panel que integra de todas sus dimensiones para un amplio conjunto de países y territorios. Se analiza el periodo 2000-2024 para las variables explicativas y utiliza calificaciones soberanas hasta el año 2025; estudiando así etapas económicas muy diferentes e importantes como la crisis de 2008-2009, la crisis de deuda soberana europea, su recuperación, la pandemia y el reciente episodio inflacionista. Cada observación corresponde a un país y un años; los indicadores fundamentales observados en el año t se utilizan para estimar la calificación vigente del año $t+1$. De esta forma se evita la incorporación de información futura.

La elevada (y casi persistente) estabilidad de las calificaciones soberanas constituye la principal dificultad. Las agencias mantienen en numerosas ocasiones la calificación del años anterior. Por ello, repetir el rating actual puede producir un error reducido sin incorporar información sobre la evolución del país. El análisis debe distinguir entre estimar el nivel futuro de la calificación y anticipar una mejora o un deterioro, eventos menos frecuentes y más sensibles a acontecimientos extraordinarios.

La pregunta principal es: **¿hasta qué punto los fundamentales económicos, fiscales, externos, institucionales y políticos permiten explicar y predecir la calificación soberana del periodo siguiente?** De forma complementaria, se estudia si esas variables ayudan a identificar los casos de mejora, estabilidad y deterioro.

Para responder se construye una base de panel con 3.434 observaciones de 159 países y territorios, se comparan modelos estadísticos y de aprendizaje automático y se aplica una validación estrictamente temporal. Entre los modelos basados solo en fundamentales, es decir excluyendo el rating del años anterior, Random Forest ofrece el mejor equilibrio entre precisión, estabilidad y coherencia. En test alcanza un MAE de 4,988 puntos y un R^2 de 0,928. Sin embargo, la persistencia obtiene un error global inferior, confirmando que el nivel y el cambio del rating son problemas distintos.

1.2 OBJETIVOS Y APORTACIONES

El objetivo principal del trabajo es analizar y modelizar el riesgo país a partir de las calificaciones crediticias soberanas utilizando variables económicas, financieras, políticas.... Mediante técnicas estadísticas y de aprendizaje automático para estimar el rating del periodo siguiente.

Para alcanzar el objetivo general se plantean los siguientes objetivos específicos:

1. Unificar en una base de datos información macroeconómica, fiscal, externa, monetaria, institucional, política, de conflicto y de default soberano. (2000-2024)
2. Homogeneizar los ratings de las tres empresas en una escala de 0-100.
3. Comparar todos los modelos mediante una división cronológica.
4. Seleccionar el modelo con mejor comportamiento fuera de muestra y estudiar la importancia de las variables utilizadas para estimar el rating soberano.
5. Comparar los modelos fundamentales con un benchmark de persistencia basado en utilizar el rating actual como predicción del rating futuro.
6. Analizar de forma complementaria la capacidad de los modelos para anticipar mejoras, deterioros y periodos sin cambios en la calificación crediticia.
7. Desarrollar una **herramienta interactiva** que permita consultar y visualizar los datos, las calificaciones soberanas y los resultados obtenidos por el modelo.

La aportación principal es un procedimiento que amplía el TFG previo: pasa de una muestra transversal de 103 países y 12 variables a un panel de 159 países, 24 años, incorpora nuevas dimensiones del riesgo, separa validación y test, introduce el benchmark de persistencia y convierte el modelo en una aplicación de consulta.

2. MARCO CONCEPTUAL Y ANTECEDENTES

2.1 CONCEPTO Y DIMENSIONES DEL RIESGO PAÍS. CALIFICACIONES SOBERANAS

El riesgo país es un concepto que engloba los factores propios de un estado que pueden afectar al cumplimiento de sus obligaciones. Se trata de un concepto multidimensional, ya que no depende únicamente de la situación económica, ni del nivel de deuda; dos países con la misma deuda pueden tener calificaciones distintas, ya que influyen otros factores como la posición fiscal y exterior, la estabilidad política, la calidad institucional, los conflictos y el historial de impago.

Dentro de este concepto puede distinguirse el riesgo soberano que se refiere específicamente a la posibilidad de que un Estado no pueda o no quiera atender sus compromisos financieros. En este trabajo, el riesgo país se analiza a través del rating soberano. Esta elección permite disponer de una medida comparable entre países y años y estudiar su relación con un amplio conjunto de variables fundamentales.

Las calificaciones de Moody's, Standard & Poor's y Fitch son opiniones sobre el nivel relativo de riesgo asociado a las obligaciones financieras de un Estado. Estas calificaciones no representan una probabilidad exacta de default, si no que su finalidad principal es ordenar a los emisores según su calidad crediticia relativa. Además de resumir información sobre la solvencia de los emisores, se emplean en decisiones de inversión, requisitos regulatorios, políticas de garantías y contratos financieros.

Las escalas empleadas por las tres agencias presentan denominaciones (ordinales) diferentes, aunque mantienen una ordenación semejante. Para poder utilizarlas conjuntamente, se han transformado las calificaciones de Moody's, Standard & Poor's y Fitch en una escala ordinal común comprendida entre 0 y 100. Los valores más elevados representan una mayor calidad crediticia y, por tanto, un menor nivel de riesgo soberano.

2.2 FACTORES ECONÓMICOS INSTITUCIONALES Y POLÍTICOS

La literatura identifica diferentes grupos de factores. Entre los económicos destacan el PIB per cápita, el cual suele estar asociado con economías más productivas y con una mayor capacidad para generar los recursos necesarios para atender la deuda, o la inflación, que por el contrario puede reflejar desequilibrios. Otros son el desempleo, la inversión y el ahorro. En el ámbito fiscal, la deuda, los saldos presupuestario y primario, los ingresos, el gasto y los pagos de intereses permiten valorar la sostenibilidad de las finanzas públicas. La posición exterior se estudia mediante la cuenta corriente, el comercio, la inversión extranjera, las reservas y la deuda externa. Las reservas proporcionan protección frente a interrupciones de financiación, mientras que la dependencia de deuda externa puede aumentar la vulnerabilidad.

Las instituciones condicionan la capacidad del Estado para diseñar y ejecutar políticas. La efectividad gubernamental, el Estado de derecho, la calidad regulatoria, el control de la corrupción, la estabilidad política y la rendición de cuentas aportan información adicional a la macroeconomía. También son relevantes la democracia, la frecuencia de los cambios de gobierno, los conflictos y el historial de default, que actúa como señal de reputación crediticia.²

Por último, el historial de default, los cambios de gobierno, la calidad democrática y la existencia de conflictos pueden modificar la percepción del riesgo.

2.3 PERSISTENCIA Y CAMBIOS EN LOS RATINGS

Los ratings soberanos presentan una elevada persistencia temporal. Las agencias tratan de evitar modificaciones provocadas únicamente por fluctuaciones transitorias, por lo que las calificaciones suelen cambiar con menos frecuencia que los indicadores económicos. Cuando no se publica una nueva acción de rating, la calificación anterior continúa vigente.

Esta estabilidad hace que el rating del año anterior contenga una gran cantidad de información sobre el rating futuro. Por ello, cualquier modelo predictivo debe compararse con un benchmark de persistencia que utilice directamente la calificación actual como estimación de la calificación del periodo siguiente. Un modelo puede explicar adecuadamente las diferencias estructurales entre países y, sin embargo, no mejorar este benchmark.

La persistencia también dificulta el análisis de los cambios. Las observaciones sin modificación son mucho más frecuentes que las mejoras y los deterioros, lo que genera un problema de clases desequilibradas. Además, algunos cambios responden a acontecimientos repentinos, como una crisis política, una guerra o un default, cuya aparición resulta difícil de anticipar mediante datos anuales.

La literatura señala que el retraso en la revisión de las calificaciones puede intensificar determinados episodios de crisis. Ferri, Liu y Stiglitz (1999) observaron un comportamiento procíclico de las agencias durante la crisis asiática, al mantener inicialmente calificaciones elevadas y aplicar posteriormente fuertes rebajas. Esta cuestión refuerza la conveniencia de analizar por separado el nivel del rating y su dirección de cambio.

2.4 ANTECEDENTES EMPÍRICOS

Uno de los estudios de referencia es el de Cantor y Packer (1996), quienes comprobaron que un grupo reducido de variables explicaba más del 90 % de la variación transversal de los ratings soberanos. Entre los factores más relevantes encontraron la renta per cápita, la deuda externa, la inflación, el nivel de desarrollo y el historial de default.

Posteriormente, Afonso, Gomes y Rother (2011) distinguieron entre determinantes de corto y largo plazo. Sus resultados muestran que los cambios en el PIB per cápita, el crecimiento, la deuda pública y el saldo presupuestario tienen efectos a corto plazo, mientras que la efectividad gubernamental, la deuda externa, las reservas y el historial de default adquieren mayor importancia a largo plazo.

Los métodos de aprendizaje automático han ampliado este campo de estudio al permitir captar relaciones no lineales e interacciones entre variables. Bennell et al. (2006) compararon modelos de redes neuronales con modelos probit ordenados y obtuvieron una mayor capacidad predictiva con las redes neuronales. Estos resultados justifican la comparación entre modelos econométricos tradicionales y algoritmos más flexibles.

El antecedente directo de este trabajo es el TFG *Estudio estadístico del riesgo país*. En aquel análisis, Random Forest fue el modelo con mejor comportamiento y alcanzó un R^2 próximo a 0,81. Entre las variables más relevantes aparecieron el PIB per cápita, la fragilidad institucional, el nivel de democracia y los préstamos bancarios no productivos.

El presente TFM amplía ese estudio e incorpora una herramienta interactiva para consultar los resultados.

3. DATOS Y CONSTRUCCIÓN DE LA BASE

3.1 FUENTES DE INFORMACIÓN

La base de datos combina información procedente de organismos internacionales, instituciones públicas y fuentes especializadas en calificaciones crediticias. La selección de las fuentes responde a tres criterios: cobertura internacional, continuidad temporal y comparabilidad entre países.

Tabla 3.1. Fuentes y dimensiones de la base

Bloque	Fuente principal	Contenido
Macroeconómico	Banco Mundial	PIB, crecimiento, renta, inflación, desempleo, inversión y ahorro
Fiscal	FMI	Deuda, saldos, ingresos, gasto e intereses
Exterior	Banco Mundial	Cuenta corriente, comercio, IED, reservas y deuda externa
Institucional	WGI	Gobernanza, regulación, Estado de derecho y corrupción
Política	V-Dem y Data360	Democracia, gobiernos, competitividad y fragilidad
Conflicto	UCDP	Conflictos armados y muertes asociadas
Default	Banco de Canadá e Inglaterra	Episodios, deuda impagada y tiempo desde el último default
Ratings	CountryEconomy y Trading Economics	Históricos de Moody's, S&P y Fitch

Los datos se obtienen mediante descargas automatizadas, APIs y ficheros oficiales. Cuando una fuente no permitía una descarga estable mediante su API, se utilizaron los archivos oficiales disponibles. Este fue el caso de los indicadores institucionales del Banco Mundial (WGI), que se incorporaron mediante un fichero estático para mantener la cobertura y la reproducibilidad del proceso.

Cada bloque se almacenó inicialmente por separado. Esta decisión permite conservar los datos originales, documentar las transformaciones realizadas y actualizar una fuente concreta sin tener que reconstruir toda la base.

3.2 UNIDAD DE ANÁLISIS Y VARIABLE OBJETIVO

La base de datos contiene información de 217 países y territorios, durante 25 años, lo que equivale a 5.425 combinaciones potenciales. Cada fila representa una entidad en un periodo.

La variable objetivo se construye a partir de las calificaciones crediticias emitidas por Moody's, Standard & Poor's y Fitch. Para cada entidad y agencia se selecciona la última calificación vigente a 31 de diciembre de cada año. Cuando no se produce una modificación, la calificación anterior se mantiene hasta que la agencia publique una nueva acción. Los años anteriores a la primera calificación permanecen ausentes.

Las escalas alfabéticas de las tres agencias se transforman en una escala numérica común comprendida entre 0 y 100. La puntuación 100 corresponde a las categorías Aaa de Moody's y AAA de Standard & Poor's y Fitch. A partir de ese nivel, la puntuación

disminuye en intervalos de cinco puntos hasta alcanzar el valor 0 en las situaciones de incumplimiento. Las categorías de default selectivo o restringido también reciben una puntuación de 0.

Cuando una entidad dispone de calificaciones de varias agencias, se calcula la media aritmética de las puntuaciones disponibles:

$$Rating_{i,t} = \frac{1}{N_{i,t}} \sum_{a=1}^{N_{i,t}} Score_{i,t,a}$$

donde $N_{i,t}$ representa el número de agencias con una calificación activa para la entidad i en el año t . Si solo existe una calificación, el rating medio coincide con la puntuación de esa agencia. La ausencia de rating se mantiene como valor ausente y no se confunde con una situación de default.

A partir de este panel se construyen tres variables:

- `rating_score_mean_t`, correspondiente al rating observado en el año de los predictores.
- `rating_score_mean_t1`, que representa el rating del año siguiente y constituye la variable objetivo principal.
- `rating_change_t1`, calculada como la diferencia entre el rating futuro y el rating actual.

La última variable permite distinguir entre mejoras, deterioros y periodos sin cambios en la calificación.

3.4 BLOQUES DE VARIABLES EXPLICATIVAS

El bloque macroeconómico recoge el crecimiento real del PIB, el PIB per cápita, el PIB y el PIB per cápita ajustados por paridad del poder adquisitivo, la inflación, el desempleo, la inversión, el ahorro y el tipo de cambio. Estas variables describen el tamaño, el nivel de desarrollo y la evolución general de la economía.

El bloque fiscal incluye la deuda pública, el saldo fiscal, el saldo primario, los ingresos, el gasto y los pagos netos de intereses, expresados principalmente como porcentaje del PIB. Su objetivo es representar la sostenibilidad presupuestaria y la capacidad del Estado para atender sus obligaciones.

La posición exterior se mide mediante el saldo por cuenta corriente, el crecimiento y el peso de las exportaciones e importaciones, la apertura comercial, la inversión extranjera directa y las reservas internacionales. También se recopilaban diferentes medidas de deuda externa, aunque varias de ellas presentan una cobertura limitada.

La dimensión institucional incorpora los seis indicadores de gobernanza del Banco Mundial: estabilidad política, efectividad gubernamental, Estado de derecho, control de la corrupción, calidad regulatoria y voz y rendición de cuentas. También se añade el índice de democracia electoral de V-Dem.

Las variables políticas recogen la duración del jefe de gobierno, la duración media de los gobiernos y el número de cambios gubernamentales recientes. El bloque de default incluye el volumen de deuda en situación de impago, la existencia de un default actual, los episodios registrados en los cinco y diez años anteriores, los años transcurridos desde el último impago y la ausencia de defaults históricos.

3.5 INTEGRACIÓN DEPURACIÓN Y MUESTRA FINAL

Los diferentes bloques se integran mediante las variables iso3 y year. Después de cada unión se comprueba que exista una única fila por entidad y año, que los periodos sean correctos y que no se hayan generado duplicados. También se homogeneizan los nombres de los países, los códigos geográficos, los tipos de datos, las unidades y el signo de las variables.

La auditoría revisa la cobertura, valores constantes, infinitos o duplicados. Las variables con más de un 40 % de valores ausentes se excluyen, entre ellas se encuentran varias medidas de deuda externa, los préstamos bancarios no productivos, el índice de competitividad y los indicadores de conflicto. Estas variables se mantienen en la base maestra para posibles análisis complementarios.

También se excluyen identificadores sin capacidad generalizable, como el nombre del jefe de gobierno. Se conservan medidas numéricas de duración y rotación política. Con las series originales se construyen medias y volatilidades móviles, cambios anuales e indicadores de recesión, inflación elevada, déficits persistentes, contracción exportadora y antecedentes de default. Todos ellos se calculan con información contemporánea o pasada.

La muestra modelizable contiene 3.434 observaciones de 159 países y 71 variables fundamentales. El fichero preparado incluye 108 columnas al añadir identificadores, variables derivadas, ratings y elementos auxiliares.

La base se conserva sin imputar ni escalar antes de realizar esta división. Los procedimientos que requieren estimar parámetros, como la imputación, la codificación de categorías o el escalado, se ajustan posteriormente utilizando únicamente el conjunto de entrenamiento. Este tratamiento permite mantener el conjunto de prueba completamente separado hasta la evaluación final.

Tabla 3.5 Resumen del proceso de integración depuración y selección de la muestra

Aspecto	Criterio o procedimiento	Resultado
Base inicial	Cuadrícula de 217 países y territorios para el periodo 2000-2024	5.425 observaciones
Integración	Unión de las fuentes mediante la clave iso3-year	Sin duplicados
Control de calidad	Revisión de tipos, unidades, valores constantes e infinitos	Sin inconsistencias estructurales
Cobertura	Exclusión de la especificación principal de las variables con más del 40 % de valores ausentes	71 variables fundamentales
Disponibilidad del objetivo	Selección de observaciones con rating disponible en el periodo siguiente	3.434 observaciones de 159 entidades
Fichero preparado	Incorporación de identificadores, variables derivadas, ratings y variables auxiliares	108 columnas

4 METODOLOGÍA

4.1 DISEÑO DEL PROBLEMA PREDICTIVO

El estudio se plantea como un problema de aprendizaje supervisado en el que las variables fundamentales observadas para el país i durante el año t se utilizan para estimar su calificación crediticia media en el año siguiente:

$$\widehat{Rating}_{i,t+1} = f(X_{i,t})$$

Se comparan dos especificaciones. La primera utiliza exclusivamente variables fundamentales económicas, fiscales, externas, institucionales y políticas. Esta especificación permite estudiar hasta qué punto el rating puede estimarse sin conocer directamente la calificación anterior. La segunda incorpora también el rating observado en el año t :

$$\widehat{Rating}_{i,t+1} = f(X_{i,t}, Rating_{i,t})$$

La segunda formulación permite analizar si las variables fundamentales aportan información adicional una vez conocida la calificación vigente. Sin embargo, debido a la elevada estabilidad temporal de los ratings, sus resultados deben compararse con un modelo de persistencia que utilice directamente el rating actual como predicción del rating futuro.


4.2 DIVISIÓN TEMPORAL DE LA MUESTRA

La división temporal reproduce una predicción real: 2000-2018 se utiliza para estimar, 2019-2021 para comparar algoritmos e hiperparámetros y 2022-2024 para la evaluación final. Una vez elegido el modelo, entrenamiento y validación se combinan y el test se utiliza una sola vez.

Tabla 4.2. División temporal de la muestra

Muestra	Predictores	Finalidad	Observaciones
Entrenamiento	2000-2018	Estimación	2.497
Validación	2019-2021	Selección	466
Test	2022-2024	Evaluación final	471

Figura 4.1. Integración, división temporal, ramas de preprocesamiento, selección y evaluación final.



4.3 PREPROCESAMIENTO DE LOS DATOS

La preparación parte de una limpieza estructural común. En esta fase se eliminan identificadores que no deben utilizarse como predictores, variables futuras y aquellas con cobertura insuficiente. También se crean las variables derivadas basadas en cambios, medias móviles, volatilidades y situaciones de vulnerabilidad. Todas ellas utilizan exclusivamente información disponible en el año t y en periodos anteriores.

Después de esta preparación común se construyen dos ramas de preprocesamiento adaptadas a las características de cada familia de modelos.

RAMA A DE MODELOS SENSIBLES A LA ESCALA

La Rama A comprende los modelos lineales y regularizados, Support Vector Regression y la red neuronal. Debido a su sensibilidad a la escala y distribución de los predictores, las variables continuas se imputan mediante la mediana del conjunto de entrenamiento y las binarias mediante el valor más frecuente, añadiendo en ambos casos indicadores de ausencia. Las variables categóricas `region` e `income_level` se imputan con la categoría más frecuente y se codifican mediante one-hot, eliminando una categoría de referencia y permitiendo categorías no observadas durante el entrenamiento.

Para reducir la asimetría y las diferencias de magnitud, se aplica una transformación logarítmica al PIB per cápita, al PIB ajustado por PPA, al PIB per cápita ajustado por PPA y a la deuda soberana en default. Posteriormente, las variables continuas se escalan mediante RobustScaler, basado en la mediana y el rango intercuartílico, lo que limita la influencia de los valores extremos sin eliminar observaciones potencialmente relevantes.

Finalmente, la multicolinealidad se analiza mediante correlaciones, factores de inflación de la varianza y relaciones exactas entre predictores, eliminando las variables redundantes. Todo el preprocesamiento se ajusta exclusivamente con el conjunto de entrenamiento y se aplica sin reestimar sus parámetros a validación y test.

RAMA B DE MODELOS BASADOS EN ÁRBOLES

La Rama B se utiliza para los árboles de decisión y los métodos de ensemble y boosting. Estos modelos construyen reglas mediante puntos de corte, por lo que no requieren que las variables estén estandarizadas ni que presenten distribuciones simétricas.

Las variables continuas se imputan mediante la mediana y las binarias mediante el valor más frecuente. En ambos casos se añaden indicadores de ausencia. Las categorías no informadas de `region` e `income_level` se sustituyen por una categoría específica denominada Missing y después se transforman mediante codificación one-hot.

No se aplican transformaciones logarítmicas ni escalado. Tampoco se recortan automáticamente los valores extremos económicamente plausibles. Este tratamiento conserva las relaciones no lineales originales y permite que los árboles identifiquen puntos de corte asociados a situaciones de crisis.

4.4 MODELOS COMPARADOS

La comparación incluye once modelos distribuidos entre las dos ramas de preprocesamiento. Se parte de métodos lineales interpretables y se incorporan progresivamente algoritmos capaces de representar relaciones no lineales e interacciones.

Tabla 4.4. Modelos comparados

Rama	Modelos	Finalidad
A	OLS, Ridge, Lasso y Elastic Net	Relaciones lineales, significatividad y regularización
A	SVR y MLP	Relaciones no lineales en datos escalados
B	Árbol de decisión	Reglas interpretables y efectos umbral
B	Random Forest y Extra Trees	Reducción de varianza mediante múltiples árboles
B	Gradient Boosting y XGBoost	Corrección secuencial de errores y regularización

La regresión lineal se emplea también con fines explicativos, utilizando coeficientes y p-valores con errores estándar robustos agrupados por país. En los demás modelos, los hiperparámetros se seleccionan exclusivamente mediante el conjunto de validación, ajustando, según el algoritmo, la intensidad de regularización, los parámetros del kernel, la arquitectura de la red, el número y profundidad de los árboles, el tamaño mínimo de las hojas y la tasa de aprendizaje.

4.5 MÉTRICAS DE EVALUACIÓN

Tabla 4.5. Métricas de evaluación

Métrica		Finalidad
Error absoluto medio	$MAE = \frac{1}{n} \sum_{i=1}^n y_i - \hat{y}_i $	Indica el número medio de puntos de rating que separa la predicción del valor real y mantiene la misma unidad que la escala de la variable objetivo.
Error cuadrático medio	$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$	Penaliza con mayor intensidad los errores elevados y permite detectar modelos que funcionan correctamente en la mayoría de las observaciones, pero generan fallos importantes en algunos países.
Coefficiente de determinación	$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$	Mide la proporción de la variabilidad del rating explicada por el modelo. Valores próximos a 1 indican una mayor capacidad explicativa.

La selección no se basa únicamente en la métrica de validación. También se compara el rendimiento entre entrenamiento y validación para detectar sobreajuste, se comprueba la estabilidad del error por año y se revisa si las predicciones permanecen dentro de la escala de 0 a 100.

Para interpretar los modelos lineales se analizan sus coeficientes. En los modelos basados en árboles se utiliza la importancia interna de las variables y la importancia por permutación. Esta última mide cuánto empeora el modelo cuando se altera aleatoriamente cada predictor y permite valorar su contribución a la predicción fuera de la muestra de entrenamiento.

4.6 BENCHMARK DE PERSISTENCIA

El benchmark de persistencia utiliza el rating actual como predicción de futuro:

$$\widehat{Rating}_{i,t+1} = Rating_{i,t}$$

Este modelo constituye una referencia imprescindible porque las calificaciones soberanas permanecen estables durante largos periodos. Si no se produce una nueva acción de las agencias, la predicción de persistencia coincide exactamente con el valor futuro.

4.7 ANÁLISIS DEL CAMBIO DE RATING

El análisis complementario transforma el cambio numérico en una variable con tres categorías:

$$Y_{i,t+1} = \begin{cases} -1 & \text{si el rating empeora} \\ 0 & \text{si el rating no cambia} \\ 1 & \text{si el rating mejora} \end{cases}$$

Debido al predominio de las observaciones sin cambio, la accuracy no se utiliza como único criterio. Un modelo podría alcanzar una tasa elevada de aciertos prediciendo siempre la clase mayoritaria y no identificar ninguna mejora ni ningún deterioro.

Por este motivo se emplean la balanced accuracy, el F1 macro y el recall de cada categoría. Estas métricas asignan mayor importancia al comportamiento conjunto sobre las tres clases. Se comparan un clasificador ingenuo, regresión logística, árbol de decisión, Random Forest, Support Vector Machine, XGBoost y un modelo logístico ordinal. También se estudian ponderaciones de clase y una estrategia en dos etapas que primero identifica si se produce un cambio y después estima su dirección.

4.8 CRITERIO DE SELECCIÓN DEL MODELO DEFINITIVO

La selección se realiza utilizando exclusivamente los resultados de entrenamiento y validación. El MAE de validación constituye el criterio principal, pero también se consideran el RMSE, el R^2 , la diferencia entre entrenamiento y validación, es decir el sobreajuste; la estabilidad temporal, la coherencia económica de las variables relevantes y el cumplimiento del intervalo de la variable objetivo. Es decir, entre dos modelos con similares métricas en validación se decantará por aquel con menor sobreajuste y mayor porcentaje de observaciones en el intervalo de la variable objetivo (0-100).

Una vez seleccionado el algoritmo y fijados sus hiperparámetros, el modelo se reestima combinando las observaciones de entrenamiento y validación. La evaluación sobre el conjunto de prueba se realiza una sola vez y no se utiliza para modificar posteriormente el modelo.

5. MODELO SELECCIONADO Y RESULTADOS

A continuación, se presentan y comparan los resultados de los modelos desarrollados en ambas ramas y se justifica la selección del modelo definitivo.

5.1. COMPARACIÓN DE LOS MODELOS


Los modelos basados en árboles y métodos *ensemble* presentaron, en general, un rendimiento superior al de las especificaciones lineales y regularizadas. Esto indica que la relación entre los fundamentales económicos, fiscales, institucionales y financieros y la calificación soberana no es completamente lineal, sino que contiene interacciones y efectos umbral.

Tabla 5.1. Principales resultados de validación con fundamentales

Modelo	MAE	RMSE	R ²
Extra Trees	4,879	7,800	0,921
Gradient Boosting	4,942	7,381	0,930
Random Forest	5,038	7,687	0,924
XGBoost	5,122	7,476	0,928
MLP. Red neuronal	6,056	8,620	0,904
Lasso	7,167	10,586	0,855
Árbol de decisión	6,880	10,677	0,853
Ridge	7,265	10,424	0,860
SVR	7,430	10,712	0,852
Elastic Net	7,179	10,586	0,855
Regresión lineal (OLS original)	7,261	10,456	0,859

Se selecciona Random Forest por el equilibrio entre precisión, generalización y coherencia de las predicciones. La configuración final utiliza 200 árboles, profundidad máxima de 15, una observación mínima por hoja y el 50 % de las variables disponibles en cada división.

Figura 5.1. MAE de validación de los principales modelos basados exclusivamente en variables fundamentales.



La selección no se basó únicamente en el menor MAE, sino también en el sobreajuste, los errores extremos y la coherencia de las predicciones con la escala de 0 a 100. Aunque Extra Trees mejora el MAE de Random Forest en 0,159 puntos, presenta un ajuste más extremo: pasa de 0,067 en entrenamiento a 4,879 en validación, frente al aumento de 1,245 a 5,038 de Random Forest.

Además, Random Forest obtiene un RMSE ligeramente inferior y un R^2 superior al de Extra Trees, manteniendo todas sus predicciones dentro del intervalo válido. Gradient Boosting y XGBoost, aunque competitivos, generan seis y cinco predicciones fuera de rango, respectivamente. Por ello, Random Forest se selecciona como modelo definitivo por ofrecer el mejor equilibrio entre precisión, estabilidad y coherencia.

5.2. ESTIMACIÓN Y EVALUACIÓN DEL MODELO DEFINITIVO


Tras la selección, entrenamiento y validación se combinan para estimar el modelo con 2.963 observaciones de 2000-2021. El preprocesamiento se reajusta con esta muestra y transforma las 71 variables fundamentales en 143 columnas. El test contiene 471 observaciones de 2022-2024 y ratings objetivo de 2023-2025.

Tabla 5.2. Resultados del Random Forest definitivo

Muestra	MAE	RMSE	R^2
Entrenamiento final	1,249	1,970	0,995
Validación	5,038	7,687	0,924
Test	4,988	7,654	0,928

En test, el error absoluto medio es inferior a cinco puntos y el modelo explica el 92,8 % de la variabilidad del rating. La proximidad de las métricas de validación y test indica estabilidad fuera de muestra, aunque la diferencia respecto al entrenamiento revela cierto sobreajuste. Ninguna predicción queda fuera del rango: el mínimo es 7,23 y el máximo 99,92.

Figura 5.2. Rating observado y rating predicho por el Random Forest definitivo en el conjunto de test.




La concentración de observaciones alrededor de la diagonal confirma la elevada asociación entre el rating observado y el estimado. No obstante, la dispersión aumenta en las calificaciones más reducidas, donde se localiza una parte importante de los errores extremos.

5.3. ESTABILIDAD TEMPORAL Y ANÁLISIS DE LOS ERRORES

Este análisis permite comprobar si el rendimiento se mantiene durante todo el periodo.

Tabla / figura 5.3. MAE por año del rating predicho

Año rating	MAE
2023	4,549
2024	5,079
2025	5,331




El MAE aumenta moderadamente desde 4,549 en 2023 hasta 5,079 en 2024 y 5,331 en 2025. El residuo medio es $-2,484$ y la mediana $-0,680$, señal de una ligera tendencia a sobreestimar la calidad crediticia causada sobre todo por pocos casos extremos. Los mayores errores aparecen en países afectados por circunstancias extraordinarias, como Rusia, Bielorrusia, Bahamas, Ghana u Omán.

El modelo utiliza información anual del periodo anterior y no puede recoger plenamente shocks posteriores, decisiones políticas o valoraciones cualitativas de las agencias. La diferencia entre RMSE y MAE es coherente con esos errores puntuales. El histograma de residuos, la tabla de casos extremos y el detalle anual se incluyen en el anexo.

5.4. IMPORTANCIA DE LAS VARIABLES

La importancia por permutación identifica como principal predictor la calidad regulatoria, seguida de los años desde el último default, el PIB en PPA, la efectividad gubernamental, la ausencia histórica de impagos, el nivel de renta, el PIB per cápita y la deuda pública. También aparecen el Estado de derecho, los pagos de intereses, las reservas y la cuenta corriente.

Figura 5.3. Principales variables según la importancia por permutación del Random Forest definitivo.



Los resultados permiten identificar cuatro grandes grupos de factores:

- **Calidad institucional:** calidad regulatoria, efectividad gubernamental, Estado de derecho y control de la corrupción.
- **Capacidad económica:** PIB total, PIB per cápita y pertenencia a niveles elevados de renta.
- **Posición fiscal y externa:** deuda pública, pagos de intereses, reservas internacionales y saldo por cuenta corriente.
- **Historial crediticio:** años desde el último impago, ausencia histórica de defaults y deuda soberana en situación de impago.

Los resultados muestran que el rating soberano depende de la interacción entre la capacidad económica, la sostenibilidad fiscal, la calidad institucional y el historial crediticio. Destacan la calidad regulatoria, la efectividad gubernamental, los antecedentes de default, la deuda pública y los pagos de intereses, que reflejan la credibilidad del Estado y la presión de sus obligaciones financieras.

Estas importancias representan asociaciones predictivas, no relaciones causales. Además, la correlación entre variables puede repartir su relevancia, por lo que una variación aislada de un indicador no implica necesariamente un cambio equivalente en el rating.

5.5. COMPARACIÓN CON EL MODELO DE PERSISTENCIA

Las calificaciones soberanas presentan una elevada estabilidad temporal. Por este motivo, se utilizó como referencia un modelo de persistencia que supone que la calificación del siguiente periodo será igual a la vigente:

$$\widehat{Rating}_{t+1} = Rating_t$$

En validación, el modelo de persistencia alcanza un MAE de 1,505 y supera a las especificaciones que combinan el rating previo con los fundamentales, debido a que la mayoría de las calificaciones no cambia. Sin embargo, el modelo basado exclusivamente en fundamentales persigue un objetivo diferente: proporcionar una valoración independiente del nivel crediticio compatible con las características económicas e institucionales de cada país.

Cuando el análisis se limita a las observaciones con cambios de rating, el MAE de persistencia aumenta hasta 5,097, mientras que Ridge con rating previo y fundamentales lo reduce a 4,857. Aunque la mejora es moderada, confirma que los fundamentales aportan información adicional. Por tanto, estimar el nivel futuro del rating resulta más sencillo que anticipar el momento y la dirección exacta de una revisión.

Tabla 5.5. Síntesis del benchmark y del análisis del cambio

Análisis	Muestra	Indicador	Resultado
Persistencia	Validación completa	MAE	1,505
Persistencia	Casos con cambio	MAE	5,097
Sistema en dos etapas	Validación	Balanced accuracy / F1	0,525 / 0,469
Sistema en dos etapas	Test	Balanced accuracy / F1	0,514 / 0,465

5.6. ANÁLISIS COMPLEMENTARIO DEL CAMBIO DE RATING

Para estudiar específicamente esta segunda dimensión se definió el cambio de rating como:

$$\Delta Rating_{t+1} = Rating_{t+1} - Rating_t$$

Los cambios de rating se clasifican como mejora, deterioro o ausencia de cambio. En el conjunto de test, el 74,2 % de las observaciones permanece estable, frente al 17,7 % de mejoras y el 8,1 % de deterioros. Debido a este desequilibrio, la evaluación se realiza mediante *balanced accuracy*, F1 macro y recall por clase, evitando que una elevada accuracy oculte la incapacidad para detectar cambios.

Ante los resultados limitados de la clasificación directa, se desarrolló un sistema en dos etapas: Extra Trees identifica si se produce una revisión y Random Forest determina si corresponde a una mejora o un deterioro. El sistema alcanza en validación una *balanced accuracy* de 0,525 y un F1 macro de 0,469; en test obtiene 0,514 y 0,465, respectivamente. La proximidad de las métricas confirma su estabilidad fuera de muestra, aunque el rendimiento continúa siendo moderado.

En test se identifica correctamente el 63,5 % de los casos sin cambio y el 59,0 % de las mejoras, mientras que el recall de los deterioros se limita al 31,6 %. Esta dificultad resulta especialmente relevante, ya que los deterioros son los acontecimientos de mayor interés para la gestión del riesgo.

Por tanto, los fundamentales contienen información útil sobre la evolución de las calificaciones, pero no permiten anticipar con suficiente precisión el momento exacto de una revisión. El análisis del cambio se mantiene como complemento del modelo principal de Random Forest, que presenta un MAE inferior a cinco puntos, estabilidad entre validación y test y predicciones coherentes con la escala. Sus resultados deben interpretarse como apoyo cuantitativo y no como sustitución del juicio experto o de las agencias.

Tabla 5.6. Resultados del sistema de clasificación del cambio de rating

Métrica	Validación	Test
Balanced accuracy	0,525	0,514
F1 macro	0,460	0,465
Recall: sin cambio	-	0,635
Recall: mejora	-	0,590
Recall: deterioro	-	0,316

6. HERRAMIENTA INTERACTIVA DE EVALUACIÓN DEL RIESGO SOBERANO

<https://riesgo-soberano-mla.streamlit.app/>

Como aplicación práctica de los resultados obtenidos, se ha desarrollado una herramienta interactiva en Python mediante Streamlit.

6.1. FUNCIONAMIENTO

El objetivo de esta herramienta es trasladar el análisis a un entorno accesible, donde el usuario pueda consultar países y periodos sin ejecutar los notebooks ni conocer los detalles de programación.

La aplicación recupera los fundamentales seleccionados, aplica el mismo preprocesamiento utilizado en la estimación y genera con Random Forest el rating del periodo siguiente. Para la información más reciente, los datos de 2024 se relacionan con la estimación de 2025. La interfaz presenta el rating observado, la predicción y su diferencia, además de gráficos históricos y tablas de apoyo.




Figura 6.1. Herramienta interactiva de evaluación del riesgo soberano.

6.2. UTILIDAD Y ALCANCE

La herramienta interactiva, desarrollada en Streamlit, traslada los resultados del trabajo a un entorno visual y accesible. Su navegación se organiza en varias pestañas. La página de Inicio presenta una visión general de la aplicación, mientras que Predicción permite seleccionar un país y un periodo para consultar el rating observado, la estimación generada por Random Forest para el año siguiente y la diferencia entre ambos valores. Por su parte, Datos e indicadores recoge las variables utilizadas, su cobertura, las fuentes de información y la metodología aplicada.

La pestaña de Comparación permite analizar simultáneamente dos países. En primer lugar, muestra indicadores como el *Risk Score*, el rating soberano, el crecimiento del PIB, la inflación y la deuda pública. El elemento principal es el gráfico de tela de araña o radar, que compara seis dimensiones de riesgo: macroeconómica, fiscal, externa, institucional, política y de estabilidad, e historial crediticio. Todas se expresan en una escala común de 0 a 100, donde los valores más elevados indican una mayor vulnerabilidad relativa. La comparación se completa con los valores originales de los indicadores, gráficos de evolución y una interpretación automática de las principales diferencias.

La pestaña de Clústeres identifica grupos de países con perfiles semejantes. Las variables se imputan y estandarizan antes de aplicar un análisis de componentes principales y el algoritmo K-Means. El plano formado por las dos primeras componentes permite visualizar los grupos, mientras que su caracterización mediante las dimensiones de riesgo facilita la interpretación económica de cada clúster.




Figura 6.2. Página comparación




Figura 6.3 *Página clusteres*

En conjunto, la aplicación permite consultar predicciones, comparar economías e identificar patrones comunes. Debe entenderse como una herramienta cuantitativa de apoyo al análisis y no como una sustitución de las agencias de calificación o del juicio experto.

7. CONCLUSIONES, LIMITACIONES Y LÍNEAS FUTURAS


7.1. PRINCIPALES CONCLUSIONES

El trabajo demuestra que los fundamentales permiten estimar con precisión el nivel futuro del rating soberano. La integración de fuentes heterogéneas, la estructura país-año y la división cronológica proporcionan un marco reproducible que evita utilizar información futura y permite evaluar el modelo sobre años recientes. Los métodos ensemble superan a las especificaciones lineales y Random Forest ofrece el mejor equilibrio global. En test obtiene un MAE de 4,988, un RMSE de 7,654 y un R^2 de 0,928, con todas las predicciones dentro de la escala. La calidad regulatoria, la efectividad gubernamental, el desarrollo económico, la deuda y el historial de default concentran la mayor capacidad predictiva.

La persistencia constituye, sin embargo, el mejor predictor agregado cuando se conoce el rating vigente. Esto no invalida el modelo fundamental: permite construir una valoración independiente y aporta cierta información en los episodios de cambio. El análisis de clasificación confirma que anticipar una revisión, especialmente un deterioro, es mucho más difícil que estimar el nivel de calificación.

La herramienta interactiva completa el estudio al facilitar la consulta de estimaciones y divergencias. El resultado final es un sistema de apoyo cuantitativo que combina datos, modelización, evaluación fuera de muestra e interpretación económica.

Figura 7.1. Síntesis de los principales resultados del modelo definitivo. Fuente: elaboración propia.



7.2. LIMITACIONES

Las principales limitaciones son la cobertura desigual y el retraso de algunas fuentes, la frecuencia anual de los datos y la necesidad de imputar valores ausentes. Estas restricciones reducen la capacidad para recoger rápidamente crisis, sanciones, conflictos o cambios políticos.

La puntuación media de las tres agencias amplía la cobertura, pero oculta diferencias en sus escalas y calendarios. Tratarla como continua también supone aproximar una variable originalmente ordinal. Además, la escasez de deterioros dificulta aprender patrones estables para la clase de mayor interés desde la perspectiva del riesgo.

Finalmente, la importancia de las variables describe asociaciones históricas y no efectos causales. Las estimaciones deben combinarse con información reciente, análisis cualitativo y juicio experto.

7.3. LÍNEAS FUTURAS DE INVESTIGACIÓN

Las extensiones más relevantes serían incorporar variables de mercado y mayor frecuencia —diferenciales soberanos, volatilidad e incertidumbre—, ampliar la información geopolítica y utilizar procesamiento del lenguaje natural sobre noticias e informes. También podrían estimarse modelos separados por agencia, métodos ordinales e intervalos de predicción.

La actualización mediante ventanas móviles permitiría comprobar si cambian las relaciones a lo largo del tiempo. Para las revisiones crediticias, sería útil emplear horizontes de dos o tres años y distinguir cambios menores de rebajas o mejoras de gran magnitud.

En síntesis, el aprendizaje automático ofrece una aproximación sólida al nivel de riesgo soberano, pero la persistencia de los ratings y los shocks inesperados obligan a interpretar el resultado como una herramienta complementaria. La aportación principal es un procedimiento completo e interpretable para integrar información, comparar metodologías y transformar las predicciones en una aplicación práctica.

8. BIBLIOGRAFIA

Definición riesgo país: <https://www.bbva.es/diccionario-economico/r/riesgo-pais.html>

The worldwide governance indicators : methodology and analytical issues

<https://documents.worldbank.org/en/publication/documents-reports/documentdetail/630421468336563314>

Afonso, A., Gomes, P. y Rother, P. (2011). Short- and long-run determinants of sovereign debt credit ratings. *International Journal of Finance & Economics*, 16(1), 1-15.

Bennell, J. A., Crabbe, D., Thomas, S. y Gwilym, O. (2006). Modelling sovereign credit ratings: Neural networks versus ordered probit. *Expert Systems with Applications*, 30(3), 415-425.

BBVA. Diccionario económico: riesgo país. <https://www.bbva.es/diccionario-economico/r/riesgo-pais.html>

Cantor, R. y Packer, F. (1996). Determinants and impact of sovereign credit ratings. *Federal Reserve Bank of New York Economic Policy Review*, 2(2), 37-53.

Ferri, G., Liu, L.-G. y Stiglitz, J. E. (1999). The procyclical role of rating agencies: Evidence from the East Asian crisis. *Economic Notes*, 28(3), 335-355.

Kaufmann, D., Kraay, A. y Mastruzzi, M. (2010). The Worldwide Governance Indicators: Methodology and analytical issues. *World Bank Policy Research Working Paper* 5430.